

一、研究背景與動機

不論是食品製造業、機械製造業、晶片製造業、...等等不同的製造業，都會有個共同的重要問題，就是如何提升自家產品的品質且降低生產成本。但是往往在整個繁瑣的製程當中無法有效掌握問題所在，總是在產生生產完成之後才知道良率如何。所以，如何從產品的品質或是良率，反推產品的製程，或是產品的成分含量比率，透過分析的方式來達到產品品質是非常重要的課題。

二、研究目的

此研究目的，最主要是收集紅、白酒相關資訊，透過迴歸分析方式來找出影響品質的主要因素，並透過調整該獨立變數的值來達到高品質的紅、白酒。初步會採用分類法則的 C5.0 來嘗試塑模與測試，先瞭解兩種酒類的判斷標準會不會一致。最後，再採取迴歸分析方式來進行塑模分析，找出一個較好的模型，來改良紅、白酒的高品質比率。

三、變數介紹

這兩個資料集(winequality-rec.csv & winequality-white.csv)是 “Vinho Verde” 酒，紅色和白色的變種酒品，透過常期收集所儲存下來的相關資料。更多資料可以參考：<http://www.vinhoverde.pt/en/> 或參考文獻[科爾特斯等，2009]。

由於隱私和後勤問題，只有物理化學（輸入）和感覺（輸出）變量是可用的（例如，沒有關於葡萄類型，葡萄酒品牌，葡萄酒售價等的數據）。

有關紅酒的資料筆數 1599；白酒的筆數 4898。共計有 11 個輸入變數(獨立變數或稱預測變數)以及一個輸出變數 quality(相依變數或稱為解釋變數)。其中完全沒有遺漏值。變數說明如表 3-1。

表 3-1 變數說明

序號	變數名稱	變數說明	變數型態	備註說明
1	fixed.acidity	固定的酸度	real	
2	volatile.acidity	揮發性酸	real	
3	citric.acid	檸檬酸	real	
4	residual.sugar	殘糖	real	

5	chlorides	氯化物	real	
6	free.sulfur.dioxide	游離二氧化硫	integer	
7	total.sulfur.dioxide	二氧化硫總量	integer	
8	density	密度	real	
9	pH	pH 值	real	
10	sulphates	硫酸鹽	real	
11	alcohol	酒精濃度	real	
12	quality	品質	integer	0 到 10 之間的分數

先利用 R 語言將資料讀入查看資料內容如下，分別為 red(紅酒)與 white(白酒)的資料前六筆資料。

```
> red <- read.table(file="winequality-red.csv",header=TRUE,sep=";")
> white <- read.table(file="winequality-white.csv",header=TRUE,sep=";")
> head(red)
fixed.acidity volatile.acidity citric.acid residual.sugar chlorides
1      7.4          0.70     0.00       1.9    0.076
2      7.8          0.88     0.00       2.6    0.098
3      7.8          0.76     0.04       2.3    0.092
4     11.2          0.28     0.56       1.9    0.075
5      7.4          0.70     0.00       1.9    0.076
6      7.4          0.66     0.00       1.8    0.075

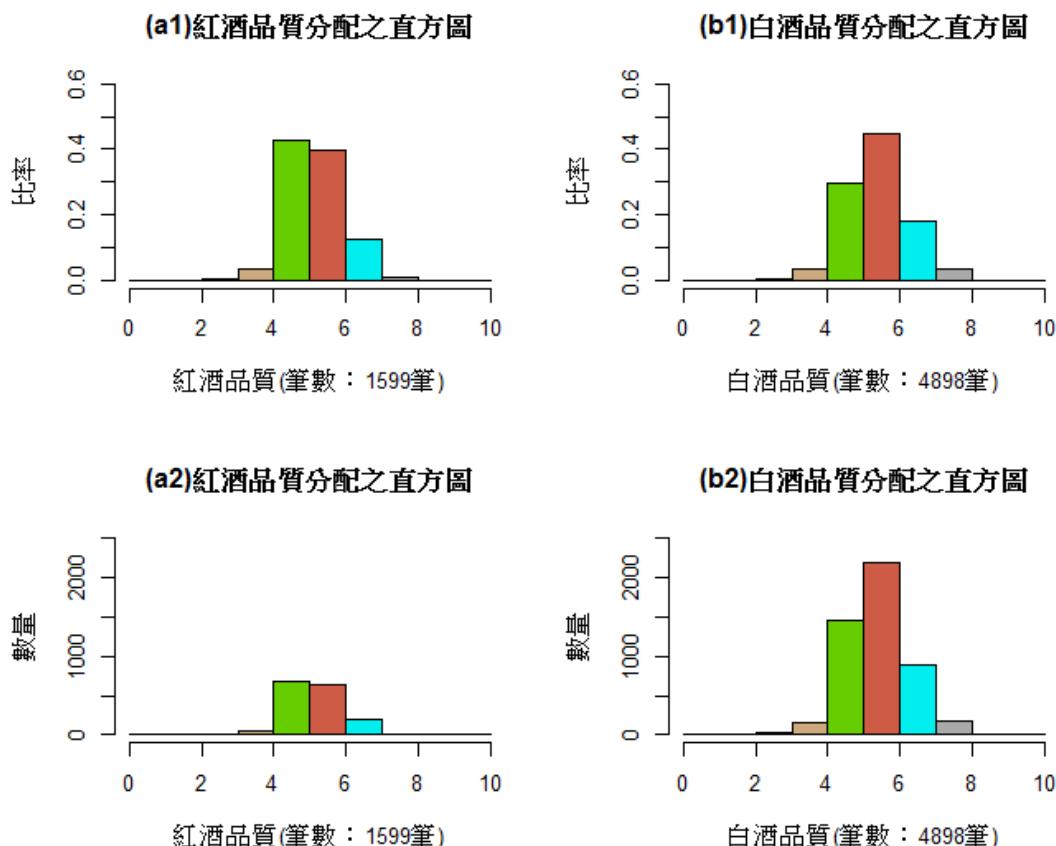
free.sulfur.dioxide total.sulfur.dioxide density    pH sulphates alcohol quality
1            11                  34  0.9978 3.51      0.56    9.4    5
2            25                  67  0.9968 3.20      0.68    9.8    5
3            15                  54  0.9970 3.26      0.65    9.8    5
4            17                  60  0.9980 3.16      0.58    9.8    6
5            11                  34  0.9978 3.51      0.56    9.4    5
6            13                  40  0.9978 3.51      0.56    9.4    5

> head(white)
fixed.acidity volatile.acidity citric.acid residual.sugar chlorides
1      7.0          0.27     0.36      20.7    0.045
2      6.3          0.30     0.34       1.6    0.049
3      8.1          0.28     0.40       6.9    0.050
4      7.2          0.23     0.32       8.5    0.058
5      7.2          0.23     0.32       8.5    0.058
6      8.1          0.28     0.40       6.9    0.050

free.sulfur.dioxide total.sulfur.dioxide density    pH sulphates alcohol quality
1            45                  170  1.0010 3.00      0.45    8.8    6
2            14                  132  0.9940 3.30      0.49    9.5    6
```

3	30	97	0.9951	3.26	0.44	10.1	6
4	47	186	0.9956	3.19	0.40	9.9	6
5	47	186	0.9956	3.19	0.40	9.9	6
6	30	97	0.9951	3.26	0.44	10.1	6
>							

先從紅、白酒的製造品質的分佈情況來瞭解製造品質情況，從下圖可以很明顯，以比率而言(a1)的紅酒與(b1)白酒的大多數百分比都是落於[5,7]的區間內。反而，從實際數量的(a2)與(b2)比較看不出兩者共通性，因為數量差距太大。



為了先瞭解獨立變數對相依變數 quality 的重要性，初步採用 C5.0 的分類法則演算法試著塑模與預測。並且，為了能夠瞭解紅酒與白酒的品質是否會有相同的因素，所以會將此兩個資料集分別各自執行一次，再來評估結果，以做為後續採用迴歸分析之參考與比較。

```
# 【C5.0 演算法{C50}】 -----
install.packages("C50",repos="http://ftp.yzu.edu.tw/CRAN/")
library("C50")

# 【(1)C5.0 training phase】 -----
modeling.C50 <- function(data) {
  set.seed(300)
```

```

s <- sample(1:nrow(data),round(nrow(data)*0.5))
data.train <- data[s,]
data.test <- data[-s,]
rule <- C5.0(factor(data.train$quality)~.,data=data.train)

# 【(2)C5.0 predict(test) phase】 -----
pred <- predict(rule, data.test)
tb <- table("實際品質"=data.test$quality,"預測品質"=pred)
return(list(tb=tb,summary=summary(rule)))
}

r <- modeling.C50(data=red)
r$summary
r$tb

w <- modeling.C50(data=white)
w$summary
w$tb

```

表 3-2 紅、白酒的因素使用率

紅酒的因素使用率	白酒的因素使用率
Attribute usage:	Attribute usage:
100.00% alcohol	100.00% alcohol
98.75% total.sulfur.dioxide	84.81% volatile.acidity
88.50% sulphates	79.42% fixed.acidity
73.00% volatile.acidity	79.26% free.sulfur.dioxide
47.63% residual.sugar	65.33% citric.acid
46.50% chlorides	62.92% pH
36.88% free.sulfur.dioxide	60.96% chlorides
28.88% pH	58.35% sulphates
28.75% citric.acid	57.49% residual.sugar
28.50% fixed.acidity	47.49% total.sulfur.dioxide
5.13% density	37.73% density

表 3-3 紅、白酒的預測情況

紅酒的正確情況							白酒的正確情況								
預測品質		實際品質						預測品質		實際品質					
實際品質		3	4	5	6	7	8	3	0	0	5	3	0	0	0
實際品質		3	0	1	2	1	0	0	3	0	0	5	3	0	0
		4	0	0	14	8	1	0	4	1	24	35	26	7	1

5 0 9 220 117 8 2	5 5 25 428 221 32 3 0
6 0 11 79 168 35 8	6 3 16 233 651 164 20 0
7 0 0 9 42 51 2	7 0 4 35 187 199 15 0
8 0 0 0 5 5 1	8 0 2 5 35 39 23 0
	9 0 0 1 1 0 0 0

從表 3-2 可以很明顯看出，紅、白酒對於品質的分類方式(變數)大有所不同，也就是在後續的分析當中，理當要採用分割處理，不該將資料集合併處理。

四、初步探索解釋變數

基於所搜集到的資料集如表 1，其中的『quality』品質是唯一可以當成反應變數 Y。其中的 11 個(fixed.acidity、volatile.acidity、citric.acid、residual.sugar、chlorides、free.sulfur.dioxide、total.sulfur.dioxide、density、pH、sulphates 以及 alcohol)皆可當成解釋變數 X。

表 4-1 變數說明

序號	變數名稱	變數說明	變數型態	備註說明
1	fixed.acidity	固定的酸度	real	
2	volatile.acidity	揮發性酸	real	
3	citric.acid	檸檬酸	real	
4	residual.sugar	殘糖	real	
5	chlorides	氯化物	real	
6	free.sulfur.dioxide	游離二氧化硫	integer	
7	total.sulfur.dioxide	二氧化硫總量	integer	
8	density	密度	real	
9	pH	pH 值	real	
10	sulphates	硫酸鹽	real	
11	alcohol	酒精濃度	real	
12	quality	品質	integer	0 到 10 之間的分數

4-1 建立線性模型與探討解釋變數

本節是先利用 $Y = \beta_0 + \beta_1 \times X$ 的模型來產生迴歸模型，再透過迴歸係數 β_1 來初步探討解釋變數 X 是否會影響反應變數 Y。

【R code】產出 11 個解釋變數的迴歸模型

```
# 【1.產生迴歸方程式】----  
red.wine <- read.table(file="winequality-red.csv",header=TRUE,sep=";")  
X <- c("fixed.acidity(固定的酸度)","volatile.acidity(揮發性酸)",  
      "citric.acid(檸檬酸)","residual.sugar(殘糖)",  
      "chlorides(氯化物)","free.sulfur.dioxide(游離二氧化硫)",  
      "total.sulfur.dioxide(二氧化硫總量)","density(密度)",  
      "pH(pH 值)","sulphates(硫酸鹽)","alcohol(酒精濃度)")  
  
mod <- character()  
for (i in 1:11) {  
  f <- formula(paste0("quality~",names(red.wine)[i]))  
  lm.model <- lm(f, data=red.wine)
```

```

mod <- c(mod,paste0("Y=",coef(lm.model)[[1]],
                      ifelse(coef(lm.model)[[2]]>0,"+",""),
                      coef(lm.model)[[2]],"X"))
}
names(mod) <- X
mod

```

【執行結果】

fixed.acidity(固定的酸度)

"Y=5.15732186892476+0.0575386437438816X"

volatile.acidity(揮發性酸)

"Y=6.56574550647175-1.76143778011267X"

citric.acid(檸檬酸)

"Y=5.38172490062976+0.938452038802968X"

residual.sugar(殘糖)

"Y=5.61605450900269+**0.00786511808072905**X"

chlorides(氯化物)

"Y=5.82948465954584-2.21184171639912X"

free.sulfur.dioxide(游離二氧化硫)

"Y=5.69810722357722-0.00391086710132548X"

total.sulfur.dioxide(二氧化硫總量)

"Y=5.84717920042681-**0.00454415145598421**X"

density(密度)

"Y=80.2385380208004-74.8460136014855X"

pH(pH 值)

"Y=6.63592282675891-0.301983125787391X"

sulphates(硫酸鹽)

"Y=4.8477495343891+1.19771232303137X"

alcohol(酒精濃度)

"Y=1.87497488699707+0.360841765335039X"

【說明】

從以上 11 個解釋變數的迴歸模型來初步探討，『residual.sugar』(殘糖)與『total.sulfur.dioxide』(二氧化硫總量)兩者的迴歸係數 β_1 的估計量都趨近於 0，表示這兩個解釋變數對 Y 並沒有任何的貢獻。不過，必須等後續的 t-test 才能確定是否將這兩個 X 去除掉。

4-2 透過繪圖的視覺化來探索解釋變數 X

本節主要的目的是透過繪出 X-Y 散佈圖與迴歸線的關係，再與前一章的迴歸係數做一比較與呼應。

【R code】繪出 11 個解釋變數的散佈圖與迴歸線

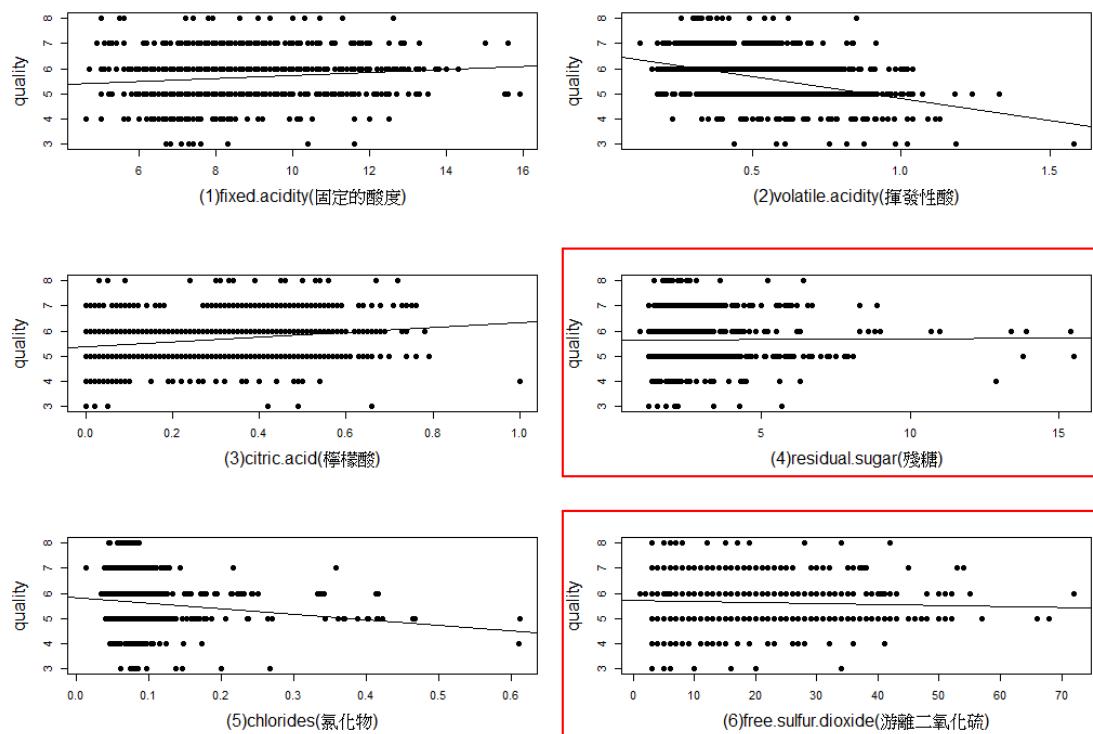
```
# 【2.畫 scatter plot 和迴歸線】----
```

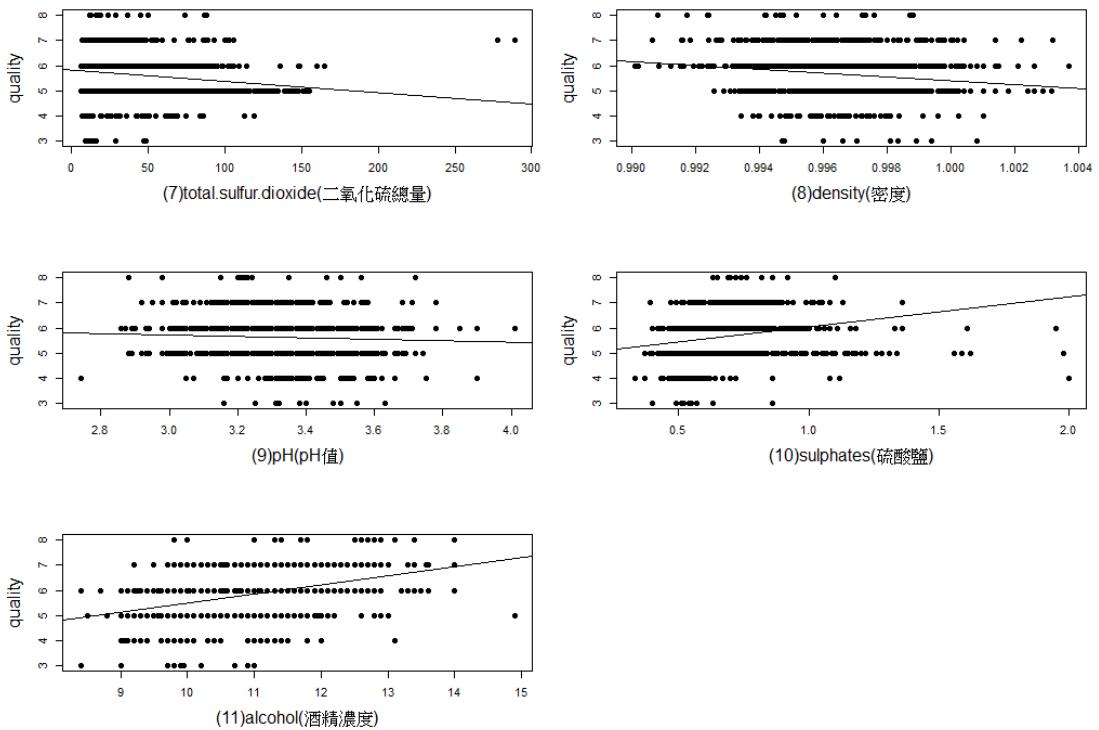
```

for (i in 1:11) {
  if (i==1 || i==7) {
    dev.new()
    par(mfrow=c(3,2))
  }
  f <- formula(paste0("quality~",names(red.wine)[i]))
  lm.model <- lm(f, data=red.wine)
  plot(red.wine[,i],red.wine$quality,cex.lab=1.5,
    xlab=paste0(",i,")",X[i]),ylab="quality",pch=19)
  abline(lm.model)
}
par(mfrow=c(1,1))

```

【執行結果】





【說明】

因為 β_1 所代表的迴歸線的斜率，所以從 11 張圖中可以很清楚地看出『residual.sugar』(殘糖)與『total.sulfur.dioxide』(二氧化硫總量)兩者的迴歸線趨於水平線。不過，這也只是與前一章的迴歸係數 β_1 互相應證。至於是否確定這兩個解釋變數應該被摒除，還要再透過下一章的 t-test 來決定。

由於 β_0 所代表的是截距，也就是當 $X=0$ 時， Y 的值。以這個個案來看，因為 Y 代表酒品的品質，分數越高代表品質越好。所以，當某一個解釋變數 X 消失時(也就是 $\beta_1 = 0$)， β_0 代表該酒品的品質分數。因此，當 β_0 越大且 β_1 的斜率又呈現負數時，代表該因素是造成品質下降的因素之一。

4-3 針對 β_0 與 β_1 的 t-test

【R code】針對 β_0 與 β_1 的 t-test

```
# 【3.針對 beta0、beta1 做 t 檢定】---
beta0.p.value <- numeric(0)
beta1.p.value <- numeric(0)
for (i in 1:11) {
  f <- formula(paste0("quality~", names(red.wine)[i]))
  lm.model <- lm(f, data=red.wine)
  s <- summary(lm.model)
  beta0.p.value <- c(beta0.p.value, coef(s)[1,4])
  beta1.p.value <- c(beta1.p.value, coef(s)[2,4])
}
```

```

names(beta0.p.value) <- X
names(beta1.p.value) <- X
names(beta0.p.value)[beta0.p.value<=0.05]
names(beta1.p.value)[beta1.p.value<=0.05]

```

【執行結果】

```

> names(beta0.p.value)[beta0.p.value<=0.05]
[1] "fixed.acidity(固定的酸度)"
[2] "volatile.acidity(揮發性酸)"
[3] "citric.acid(檸檬酸)"
[4] "residual.sugar(殘糖)"
[5] "chlorides(氯化物)"
[6] "free.sulfur.dioxide(游離二氧化硫)"
[7] "total.sulfur.dioxide(二氧化硫總量)"
[8] "density(密度)"
[9] "pH(pH 值)"
[10] "sulphates(硫酸鹽)"
[11] "alcohol(酒精濃度)"

> names(beta1.p.value)[beta1.p.value<=0.05]
[1] "fixed.acidity(固定的酸度)"
[2] "volatile.acidity(揮發性酸)"
[3] "citric.acid(檸檬酸)"
[4] "chlorides(氯化物)"
[5] "free.sulfur.dioxide(游離二氧化硫)"
[6] "total.sulfur.dioxide(二氧化硫總量)"
[7] "density(密度)"
[8] "pH(pH 値)"
[9] "sulphates(硫酸鹽)"
[10] "alcohol(酒精濃度)"

```

【說明】

從以上的結果可以明確地看出，在以下的檢定中，所有的解釋變數都顯著，拒絕 $\beta_0 = 0$ ；換言之，這 11 個解釋變數的 β_0 皆不為 0。

$$\begin{cases} H_0: \beta_0 = 0 \\ H_a: \beta_0 \neq 0 \end{cases}$$

不過，針對以下的檢定中，卻只有 10 個解釋變數是顯著，獨缺一個解釋變數『residual.sugar』(殘糖)。換言之，我們無法拒絕它的 $\beta_0 = 0$ 。與前兩章所提到的這兩個『residual.sugar』(殘糖)與『total.sulfur.dioxide』(二氧化硫總量)解釋變數有可能不影響 Y，命中了『residual.sugar』(殘糖)。

$$\begin{cases} H_0: \beta_1 = 0 \\ H_a: \beta_1 \neq 0 \end{cases}$$

表 4-2 : 11 個解釋變數的 β_0 與 β_1 檢定結果

序號	變數名稱	變數說明	β_0 test	β_1 test
1	fixed.acidity	固定的酸度		
2	volatile.acidity	揮發性酸		
3	citric.acid	檸檬酸		
4	residual.sugar	殘糖		X
5	chlorides	氯化物		
6	free.sulfur.dioxide	游離二氧化硫		
7	total.sulfur.dioxide	二氧化硫總量		
8	density	密度		
9	pH	pH 值		
10	sulphates	硫酸鹽		
11	alcohol	酒精濃度		

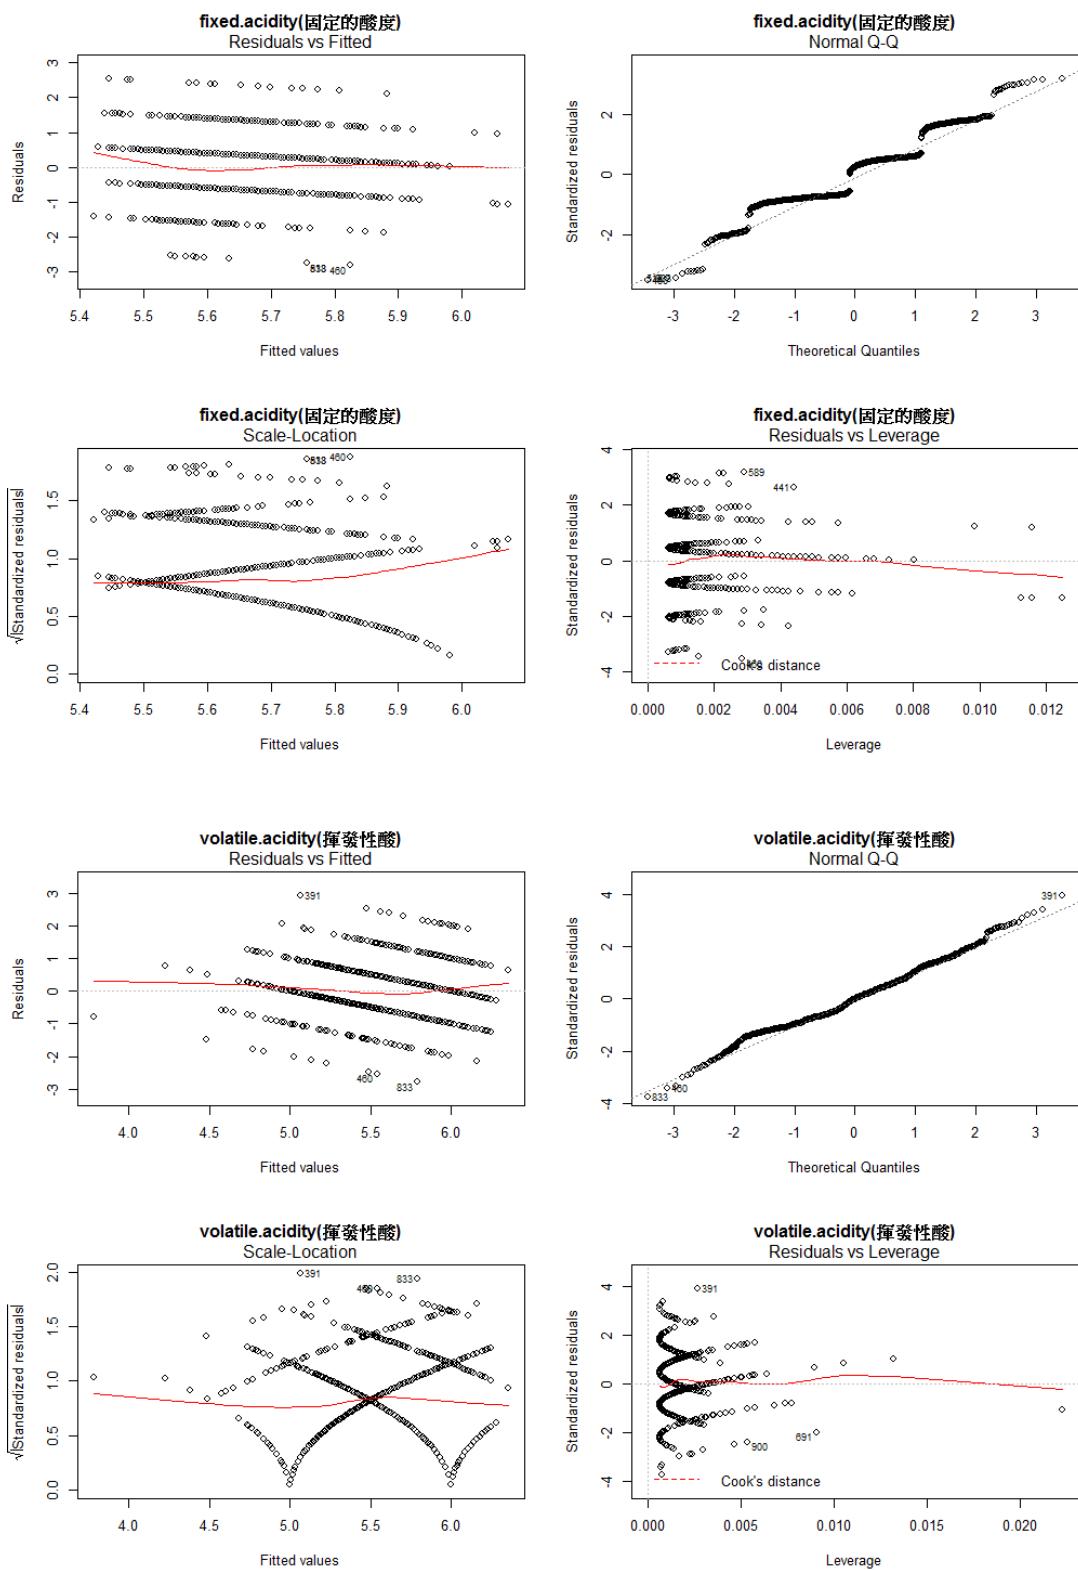
4-4 模型的殘差繪圖診斷

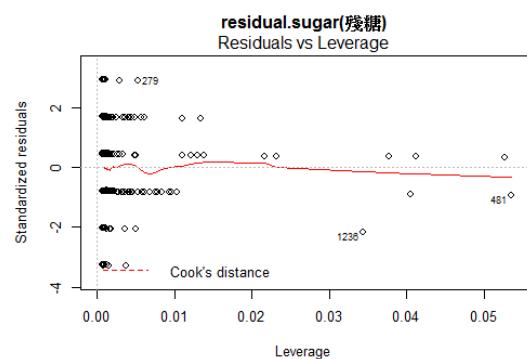
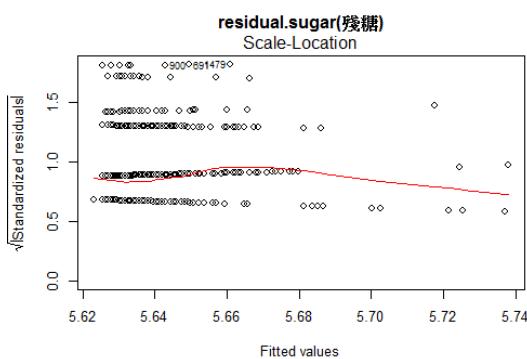
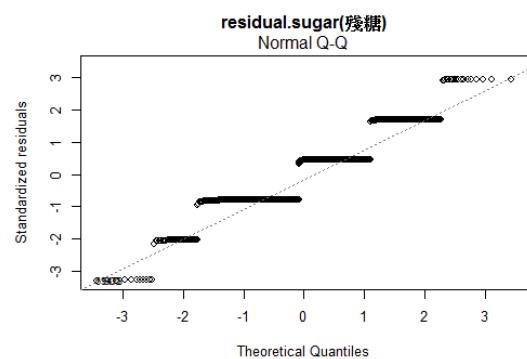
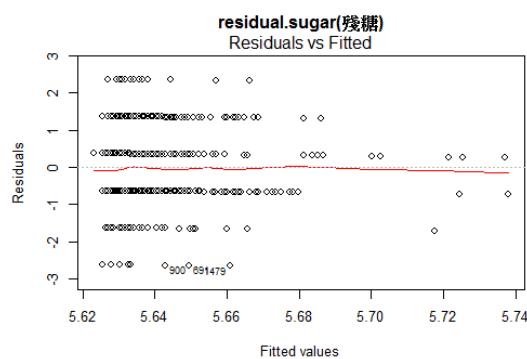
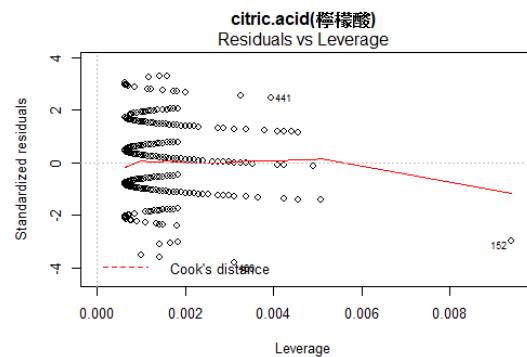
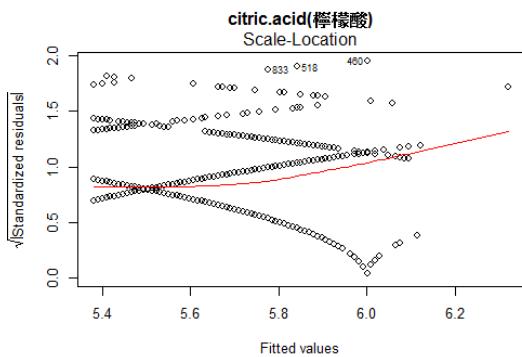
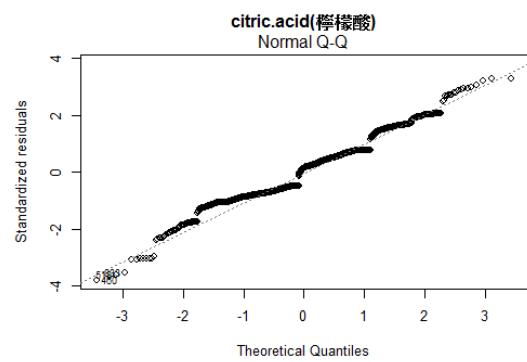
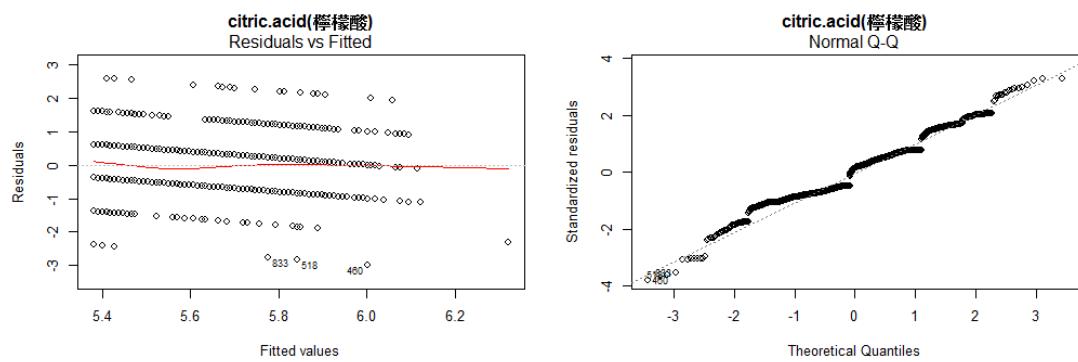
一個好的迴歸模型，殘差應該服從 Normal Distribution，所以可以透過 Q-Q plot 來察看是否標準殘差是否在對角線上。以及殘差與配適值之間的關係，殘差應該隨機分配於水平線殘差=0 的上下。

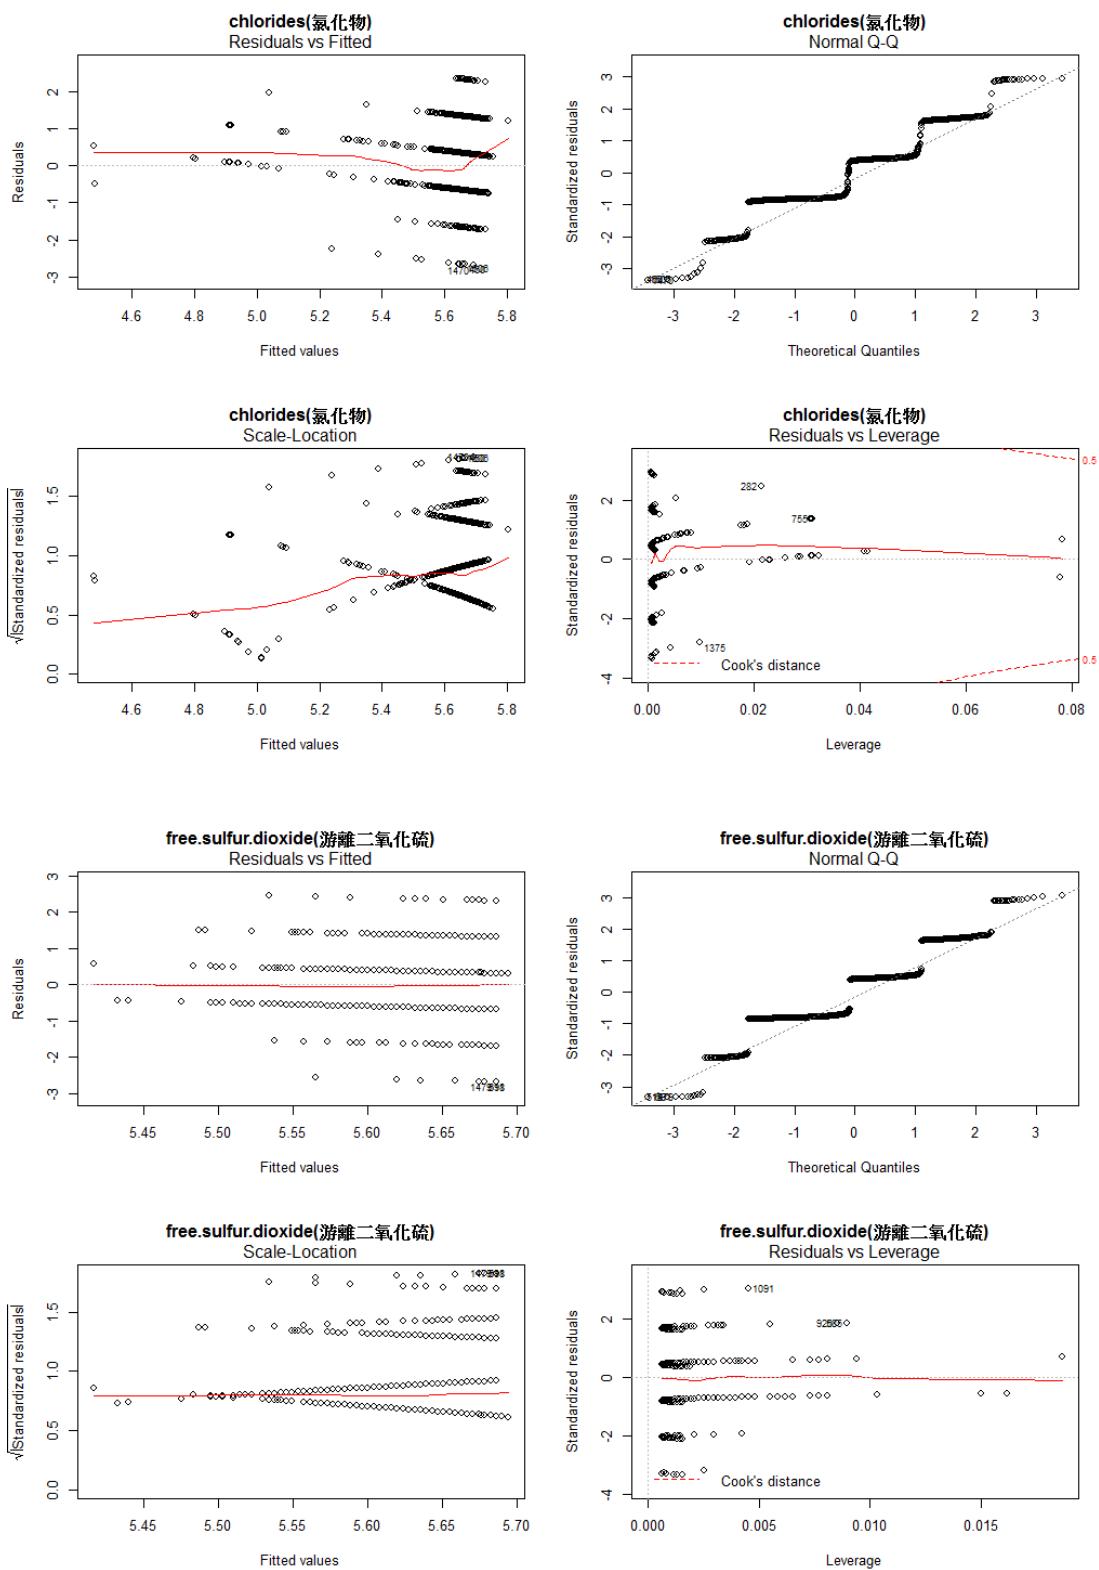
【R code】

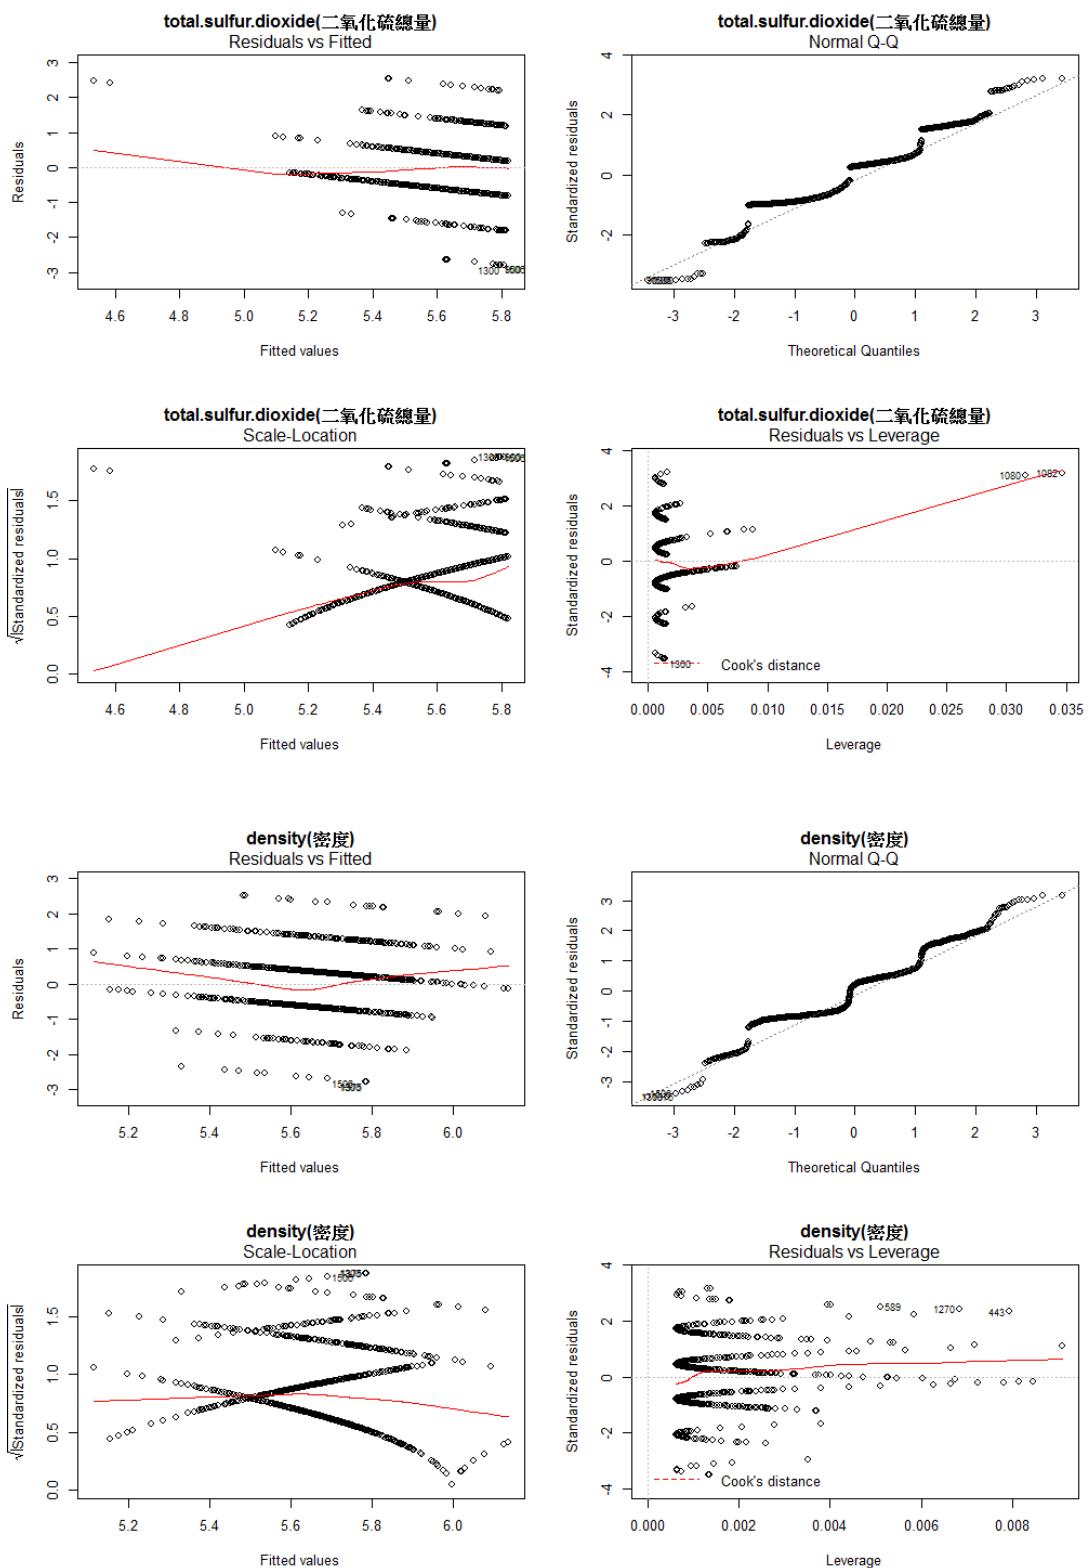
```
# 【4. 繪出四張圖，模型診斷】----
for (i in 1:11) {
  dev.new()
  par(mfrow=c(2,2))
  f <- formula(paste0("quality~",names(red.wine)[i]))
  lm.model <- lm(f, data=red.wine)
  plot(lm.model,main=X[i])
}
par(mfrow=c(1,1))
```

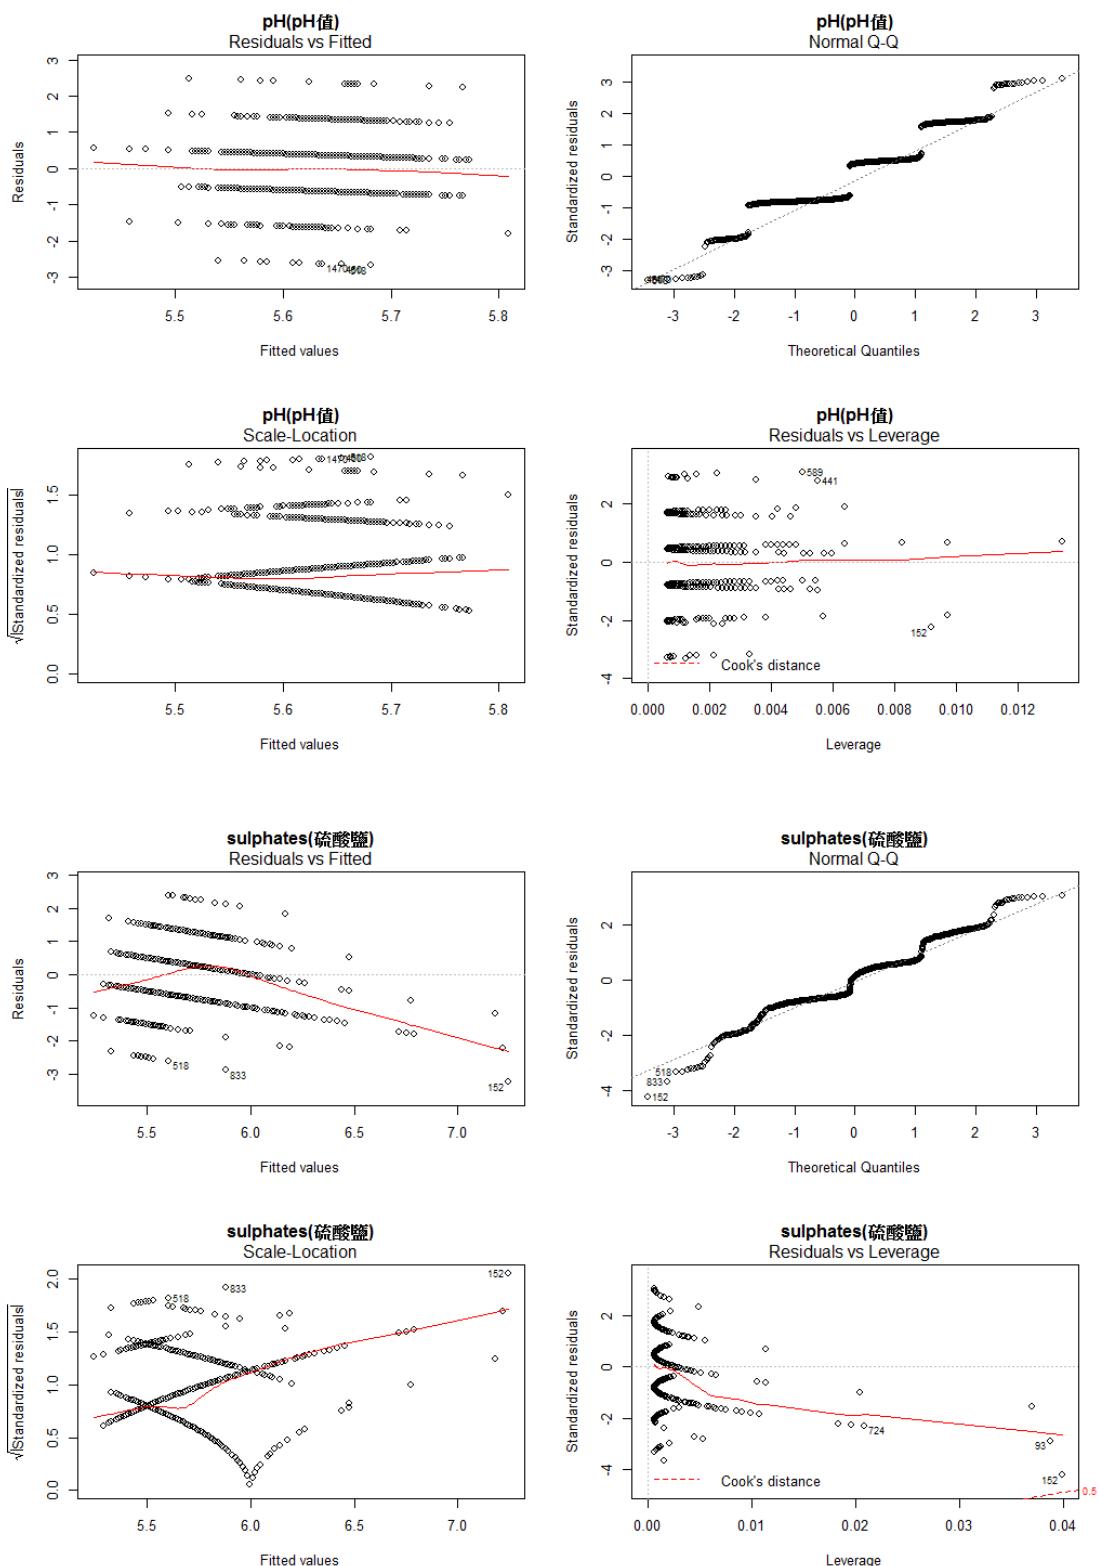
【執行結果】

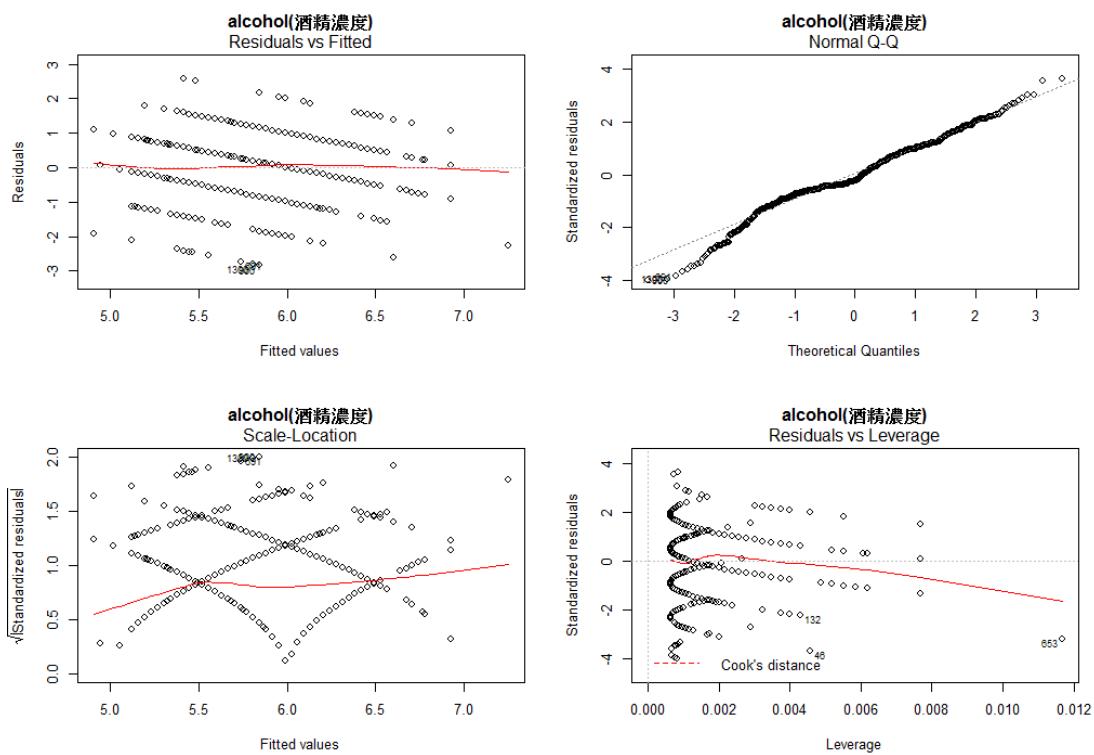












【說明】

從“殘差”(Residuals)和“配適值”Fitted values”來看，必須要儘量符合隨機分配。Fixed.acidity(固定的酸度)、volatile.acidity(揮發性酸)、citric.acid(檸檬酸)、residual.sugar(殘糖)、free.sulfur.dioxide(游離二氧化硫)、density(密度)、pH(pH 值)以及 alcohol(酒精濃度)皆符合隨機分配 Residuals=0 的水平線上下分配。

從『Q-Q Plot』來看，volatile.acidity(揮發性酸)的“殘差”最符合 Normal Distribution。Alcohol(酒精濃度)次之，倘若去除離群值，也會很符合 Normal Distribution。Fixed.acidity(固定的酸度)、citric.acid(檸檬酸)、density(密度)、total.sulfur.dioxide(二氧化硫總量)以及 sulphates(硫酸鹽)更次之。

表 4-3 : 11 個解釋變數的繪圖整理

序號	解釋變數	變數說明	β_0 test	β_1 test	Q-Q Plot	殘差與 配適值
1	fixed.acidity	固定的酸度				◎
2	volatile.acidity	揮發性酸			◎	◎
3	citric.acid	檸檬酸				◎
4	residual.sugar	殘糖		X		◎
5	chlorides	氯化物				
6	free.sulfur.dioxide	游離二氧化硫				◎
7	total.sulfur.dioxide	二氧化硫總量				
8	density	密度				◎
9	pH	pH 值				◎

10	sulphates	硫酸鹽				
11	alcohol	酒精濃度		◎	◎	

4-5 預測

本節透過以下一組 11 個新值對應這 11 個解釋變數，套入此迴歸模型來看看配適出來的新值為何？

{ 6.9, 0.680, 0.12, 1.75, 0.030, 6, 13, 0.9912, 3.48, 0.42, 12.5 }

【R code】透過此迴歸模型來 fit 新值

```
# 【5.predict 新值】----
fit <- numeric(0)
new.X <- c(6.9, 0.680, 0.12, 1.75, 0.030, 6, 13, 0.9912, 3.48, 0.42, 12.5)
for (i in 1:11){
  f <- formula(paste0("quality~",names(red.wine)[i]))
  lm.model <- lm(f, data=red.wine)
  new.dataframe <- data.frame(new.X[i])
  names(new.dataframe) <- names(red.wine)[i]
  p <- predict.lm(lm.model, new.dataframe, interval="prediction")
  fit <- c(fit, p[1,"fit"])
}
names(fit) <- X[1:11]
fit
```

【執行結果】

```
fixed.acidity(固定的酸度)
      5.554339
volatile.acidity(揮發性酸)
      5.367968
citric.acid(檸檬酸)
      5.494339
residual.sugar(殘糖)
      5.629818
chlorides(氯化物)
      5.763129
free.sulfur.dioxide(游離二氧化硫)
      5.674642
total.sulfur.dioxide(二氧化硫總量)
      5.788105
density(密度)
      6.051169
pH(pH 值)
```

5.585022
sulphates(硫酸鹽)
 5.350789
alcohol(酒精濃度)
 6.385497

4-6 整體性的分析，針對 11 個解釋變數的 ANOVA 變異數分析

F 檢定和 t 檢定的等價性($F = t^2$)，此章將驗證是否與前面的 t-test 是否相同的結果。以下將針對以下假設來檢定。

$$\begin{cases} H_0: \beta_1 = 0 \\ H_a: \beta_1 \neq 0 \end{cases}$$

【R code】

```
# 【6.ANOVA 變異數分析】----
anova <- data.frame()
for (i in 1:11) {
  f <- formula(paste0("quality~",names(red.wine)[i]))
  lm.model <- lm(f, data=red.wine)
  anova <- rbind(anova,data.frame(anova(lm.model)[1,"F
value"],anova(lm.model)[1,"Pr(>F)"]))
}
rownames(anova) <- X[1:11]
colnames(anova) <- c("F.value","p.value")
anova
```

【執行結果】

	F.value	p.value
fixed.acidity(固定的酸度)	24.9600375	6.495635e-07
volatile.acidity(揮發性酸)	287.4444497	2.051715e-59
citric.acid(檸檬酸)	86.2577262	4.991295e-20
residual.sugar(殘糖)	0.3011837	5.832180e-01
chlorides(氯化物)	26.9856084	2.313383e-07
free.sulfur.dioxide(游離二氧化硫)	4.1085023	4.283398e-02
total.sulfur.dioxide(二氧化硫總量)	56.6578176	8.621703e-14
density(密度)	50.4052231	1.874957e-12
pH(pH 值)	5.3404622	2.096278e-02
sulphates (硫酸鹽)	107.7404330	1.802088e-24
alcohol (酒精濃度)	468.2670106	2.831477e-91

【說明】

從以上的結果，**residual.sugar**(殘糖)再次被淘汰，就如同前面的 t-test 的結果相同。於是我們再將結果加入表 4。

表 4-4 : 11 個解釋變數 ANOVA 的 F 檢定

序號	解釋變數	變數說明	β_0 test	β_1 test	Q-Q Plot	殘差與 配適值	F test
1	fixed.acidity	固定的酸度				◎	
2	volatile.acidity	揮發性酸			◎	◎	◎
3	citric.acid	檸檬酸				◎	
4	residual.sugar	殘糖		X		◎	X
5	chlorides	氯化物					
6	free.sulfur.dioxide	游離二氧化硫				◎	
7	total.sulfur.dioxide	二氧化硫總量					
8	density	密度				◎	
9	pH	pH 值				◎	
10	sulphates	硫酸鹽					◎
11	alcohol	酒精濃度			◎	◎	◎

4-7 R-Squared 的分析

R-Squared 對於模型的貢獻在於線性迴歸的解釋能力，所以針對 11 個解釋變數做一個比較。

【R code】

```
# 【7.R-Squared & Adjusted R-Squared 分析】----
R.square <- data.frame()
for (i in 1:11) {
  f <- formula(paste0("quality~",names(red.wine)[i]))
  lm.model <- lm(f, data=red.wine)
  R.square <- R.square <- rbind(R.square,
    data.frame(summary(lm.model)$r.squared,
      summary(lm.model)$adj.r.squared))
}
rownames(R.square) <- X[1:11]
colnames(R.square) <- c("R.squared","R.Adj.squared")
R.square
```

【執行結果】

	R.squared	R.Adj.squared
fixed.acidity(固定的酸度)	0.0153888116	0.0147722736
volatile.acidity(揮發性酸)	0.1525353797	0.1520047193
citric.acid(檸檬酸)	0.0512445152	0.0506504291
residual.sugar(殘糖)	0.0001885579	0.0004374981
chlorides(氯化物)	0.0166169012	0.0160011322
free.sulfur.dioxide(游離二氧化硫)	0.0025660361	0.0019414688

total.sulfur.dioxide(二氧化硫總量)	0.0342621170	0.0336573969
density(密度)	0.0305967362	0.0299897211
pH(pH 值)	0.0033329135	0.0027088264
sulphates(硫酸鹽)	0.0632004914	0.0626138918
alcohol(酒精濃度)	0.2267343681	0.2262501692

【說明】

根據以上 11 個解釋變數的 R-squared & Adjusted R-squared 的表現來看，可以將表現太差的，也就是對整體解釋能力太低(未達到 1%)的三個解釋變數去除，包括 residual.sugar(殘糖)、free.sulfur.dioxide(游離二氧化硫)以及 pH(pH 值)。相對地，如果取 0.05 以上，volatile.acidity(揮發性酸)、sulphates(硫酸鹽)與 alcohol(酒精濃度)在此處的表現算是最好的三個，所以將其加入表 5。

表 4-5 : 11 個解釋變數的 R-squared

序號	解釋變數	變數說明	β_0	β_1	Q-Q	殘差與 配適值	F	R
			test	test	Plot	test	squared	
1	fixed.acidity	固定的酸度				◎		
2	volatile.acidity	揮發性酸			◎	◎	◎	◎
3	citric.acid	檸檬酸				◎		
4	residual.sugar	殘糖		X		◎	X	X
5	chlorides	氯化物						
6	free.sulfur.dioxide	游離二氧化硫				◎		X
7	total.sulfur.dioxide	二氧化硫總量						
8	density	密度				◎		
9	pH	pH 值				◎		X
10	sulphates	硫酸鹽					◎	◎
11	alcohol	酒精濃度			◎	◎	◎	◎

4-8 初步變數分析結論

針對前面所做的資料分析匯整表 6，從表 6 中可以非常清楚看出 "residual.sugar"(殘糖) 這個解釋變數幾乎是可以被淘汰不納入迴歸分析的考慮因素之一。反之，表現最好的包括以下三個：

- ✓ volatile.acidity (揮發性酸)
- ✓ alcohol (酒精濃度)
- ✓ sulphates (硫酸鹽)

表 4-6 : 11 個解釋變數的檢定總整理

序號	解釋變數	變數說明	β_0	β_1	Q-Q	殘差與 配適值	F	R
			test	test	Plot	test	squared	
1	fixed.acidity	固定的酸度				◎		

2	volatile.acidity	揮發性酸			◎	◎	◎	◎
3	citric.acid	檸檬酸			◎			
4	residual.sugar	殘糖	X		◎	X	X	
5	chlorides	氯化物						
6	free.sulfur.dioxide	游離二氧化硫			◎		X	
7	total.sulfur.dioxide	二氧化硫總量						
8	density	密度			◎			
9	pH	pH 值			◎		X	
10	sulphates	硫酸鹽				◎	◎	
11	alcohol	酒精濃度		◎	◎	◎	◎	

五、模型診斷與矯正之測量

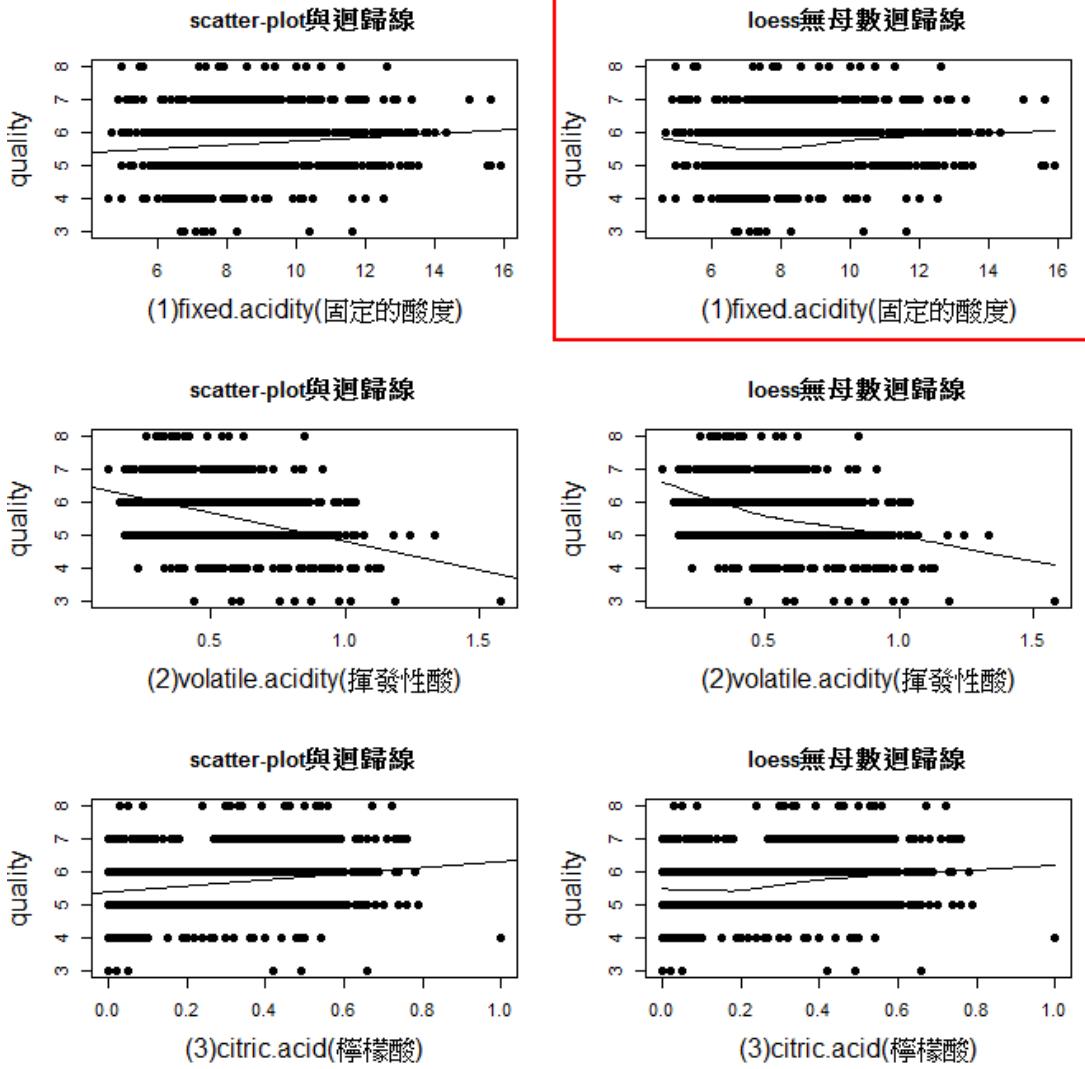
本章會先從殘差(Residuals)的圖型分佈診斷、無母數圖型分析(Levene)和 Brown-Forsythe、Breusch-Pagan 檢定，最後再透過解釋變數的轉換和反應變數的轉換(Box-Cox)來調整模型。

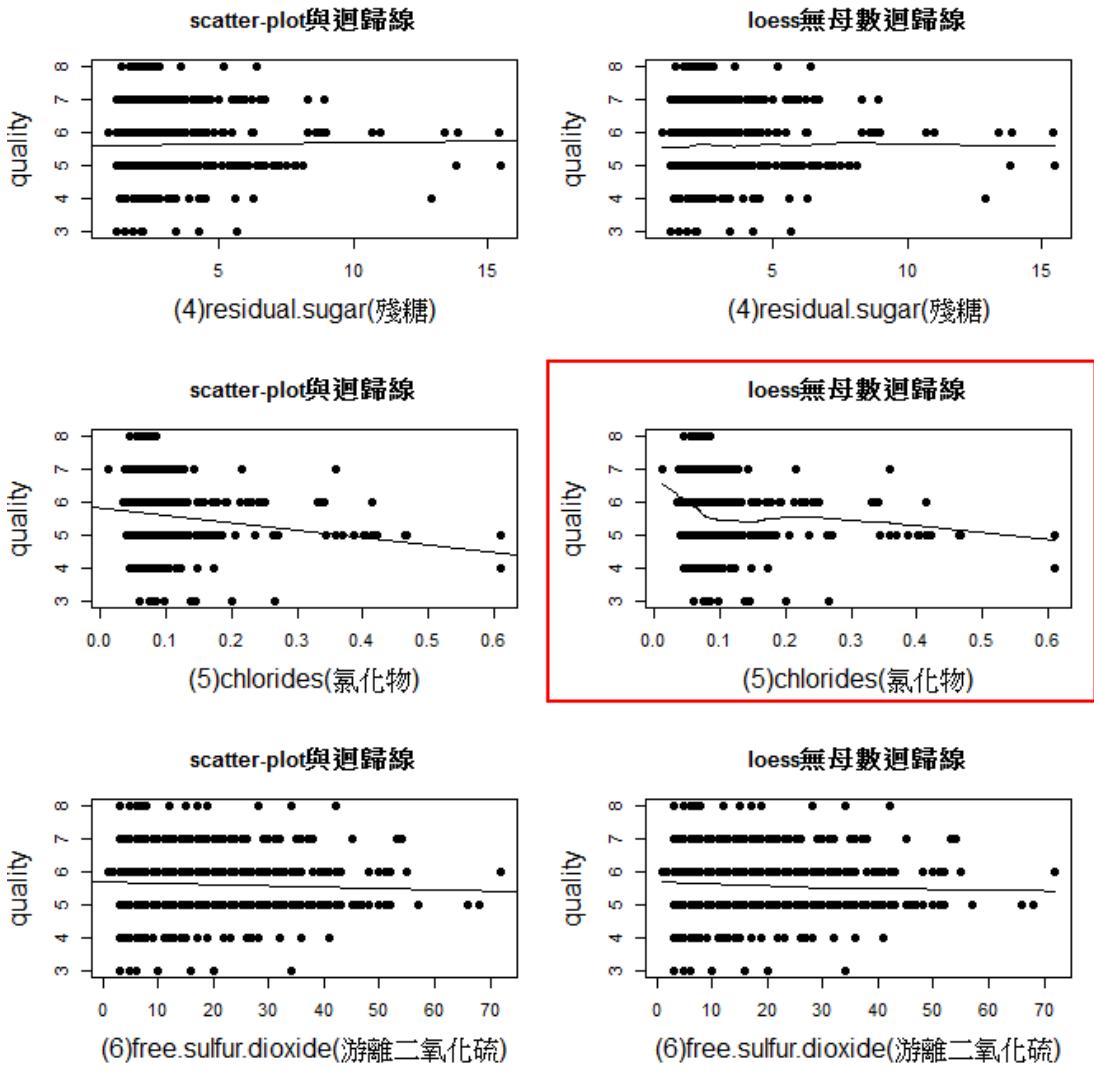
5-1 迴歸線與無母數分析圖

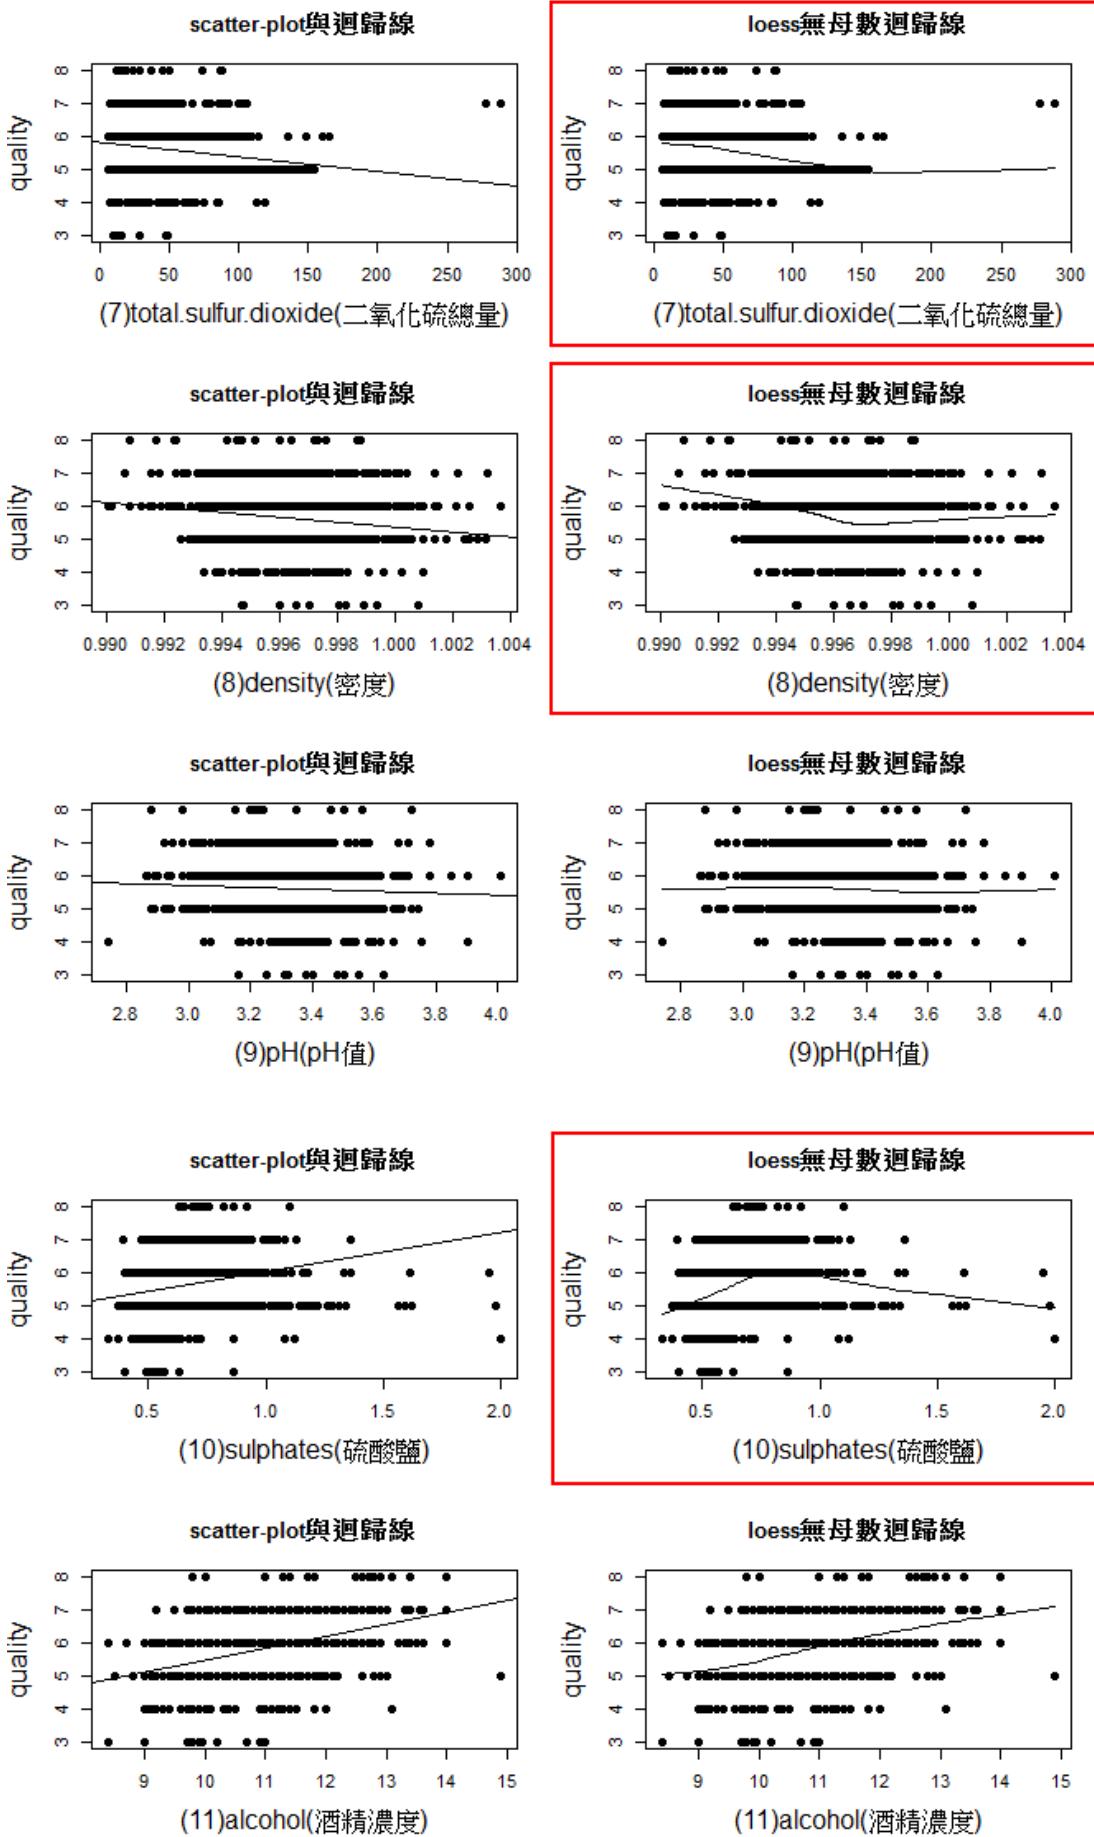
【R code】

```
# 【5-1.繪製散佈圖與迴歸線&無母數(lowess or loess)分析】----
choice.X <- c(1:11)
# choice.X <- c(2,10,11)    #可以只選擇某些解釋變數
mod <- character()
cnt <- 0
for (i in choice.X) {
  if (cnt%%3==0) {
    dev.new()
    par(mfrow=c(3,2))
  }
  cnt <- cnt + 1
  f <- formula(paste0("quality~",names(red.wine)[i]))
  lm.model <- lm(f, data=red.wine)
  plot(red.wine[,i],main="scatter-plot 與迴歸線",
        red.wine$quality,cex.lab=1.5,
        xlab=paste0("(",i,")",X[i]),ylab="quality",pch=19)
  abline(lm.model)
  plot(red.wine[,i],main="loess 無母數迴歸線",
        red.wine$quality,cex.lab=1.5,
        xlab=paste0("(",i,")",X[i]),ylab="quality",pch=19)
  lines(lowess(red.wine[,i],red.wine$quality))
}
par(mfrow=c(1,1))
```

【執行結果】





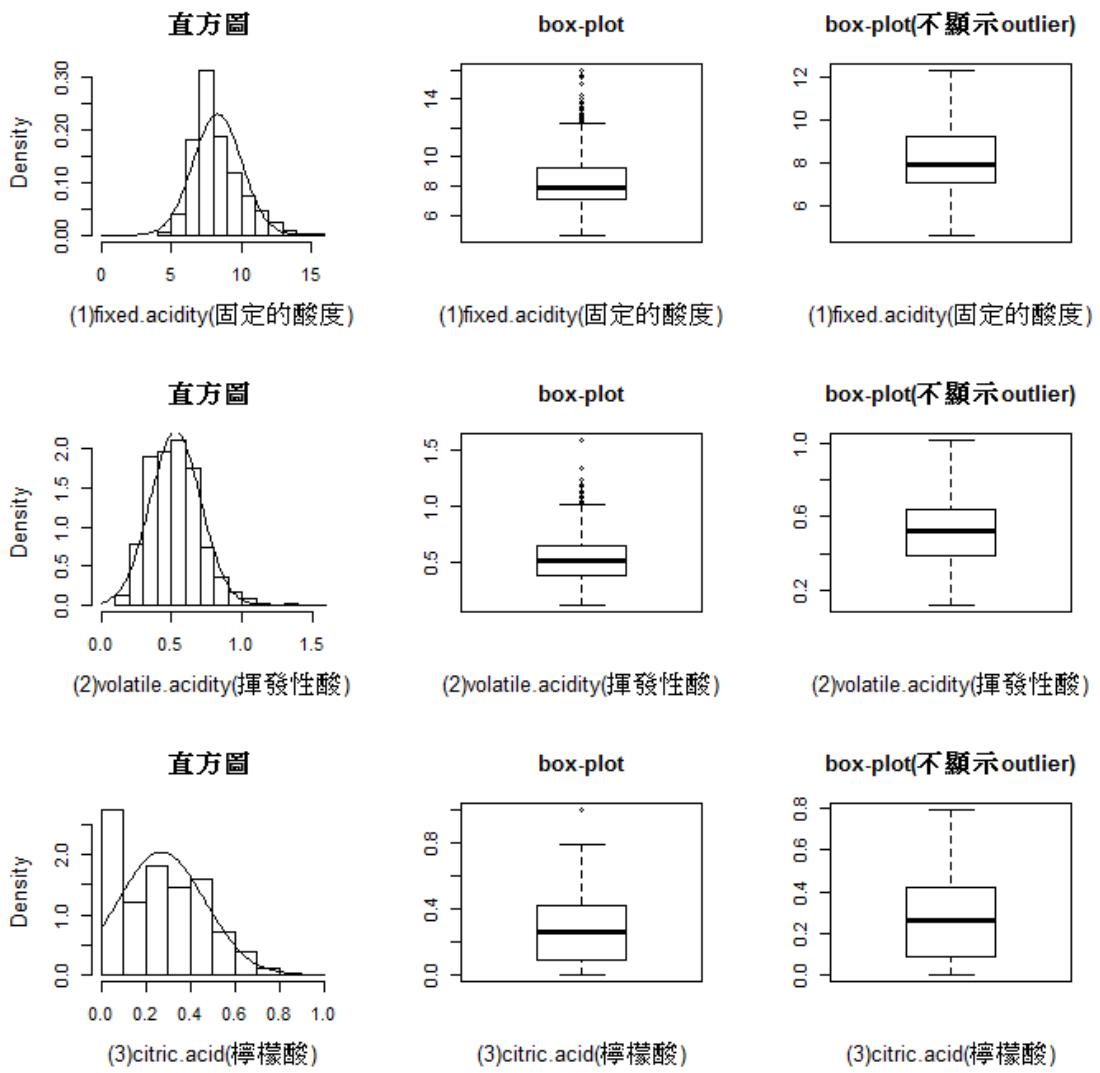


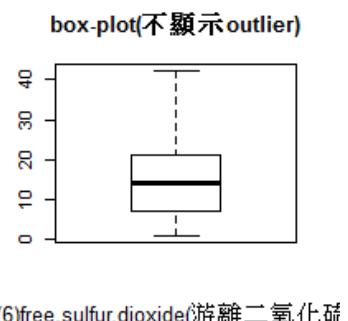
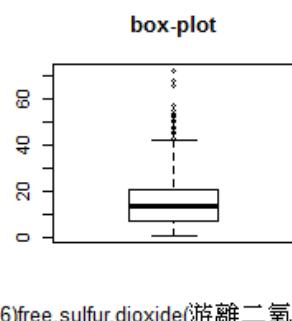
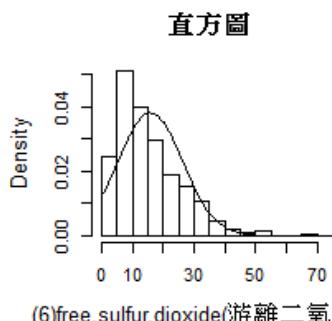
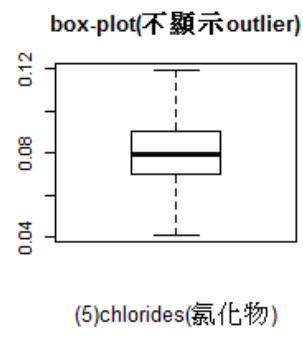
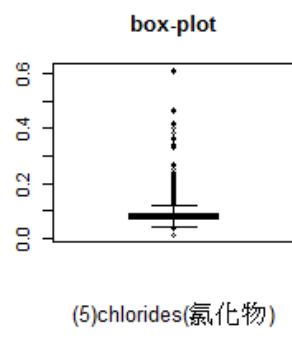
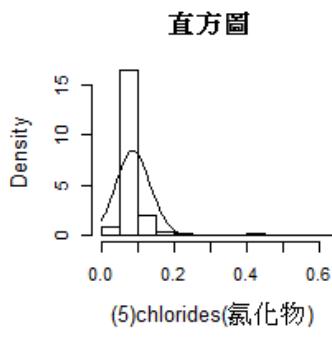
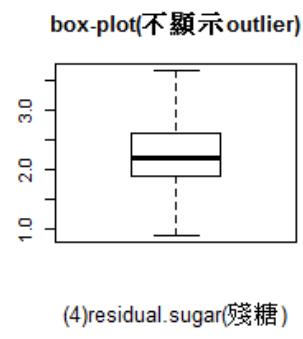
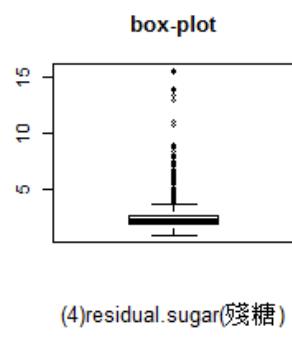
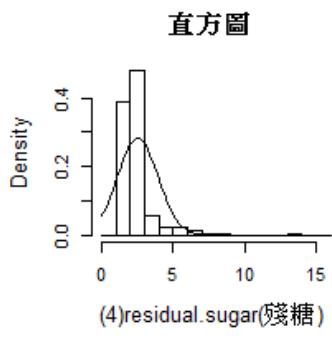
5-2 繪製 X 的直方圖(常態分配) & 盒鬚圖(box-plot)

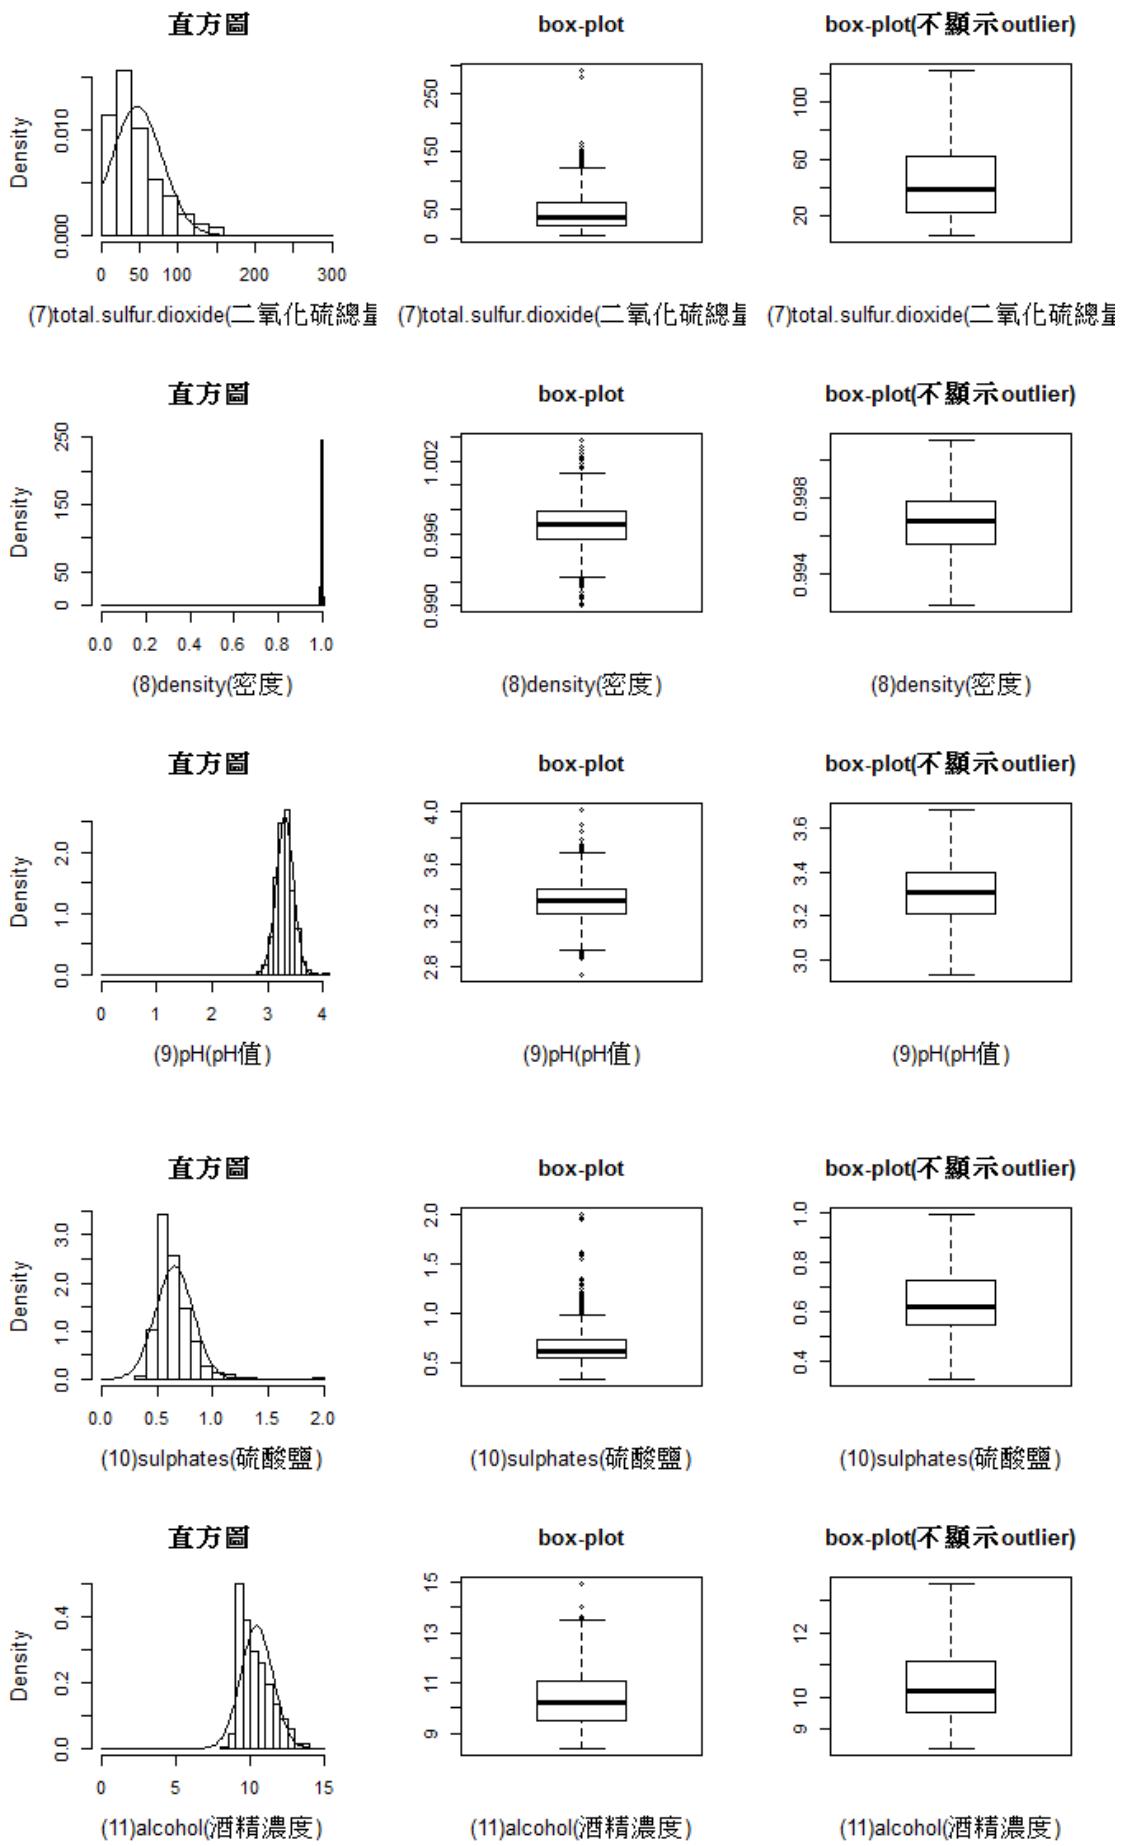
【R code】

```
# 【5-2.繪製直方圖(常態分配) & 盒鬚圖(box-plot)分析】 ----  
choice.X <- c(1:11)  
# choice.X <- c(2,10,11)    #可以只選擇某些解釋變數  
mod <- character()  
cnt <- 0  
for (i in choice.X) {  
  if (cnt%%3==0) {  
    dev.new()  
    par(mfrow=c(3,3))  
  }  
  cnt <- cnt + 1  
  f <- formula(paste0("quality~",names(red.wine)[i]))  
  lm.model <- lm(f, data=red.wine)  
  hist(red.wine[,i],main="直方圖",freq=FALSE,cex.lab=1.2,  
        xlim=c(min(0,red.wine[,i]),max(red.wine[,i])),  
        xlab=paste0("(",i,")",X[i]))  
  curve(dnorm(x,mean=mean(red.wine[,i]),sd=sd(red.wine[,i])),  
         add=TRUE)  
  boxplot(red.wine[,i],cex.lab=1.2, outline=TRUE,  
          main="box-plot", xlab=paste0("(",i,")",X[i]))  
  boxplot(red.wine[,i],cex.lab=1.2, outline=FALSE,  
          main="box-plot(不顯示 outlier)", xlab=paste0("(",i,")",X[i]))  
}  
par(mfrow=c(1,1))
```

【執行結果】





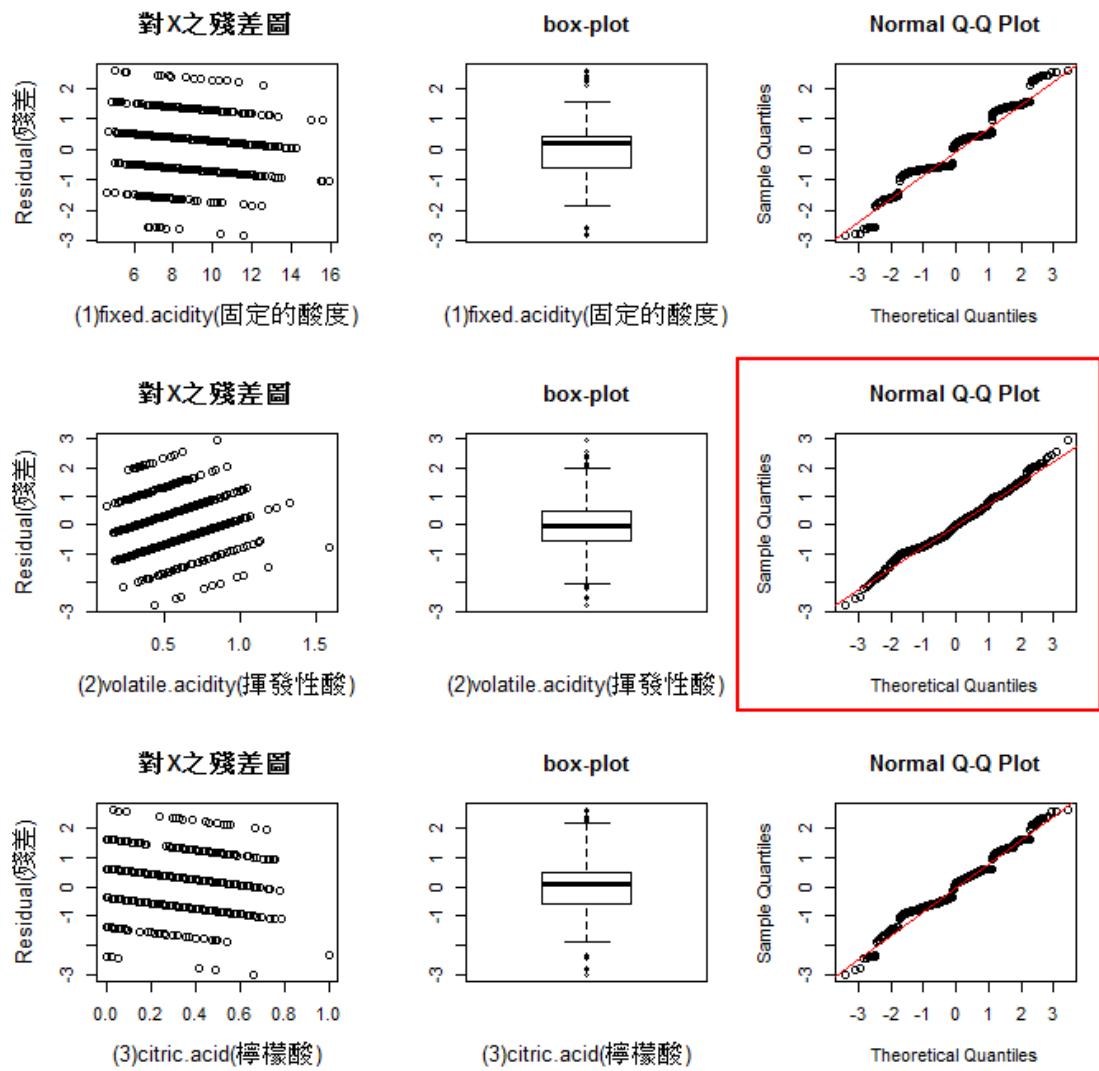


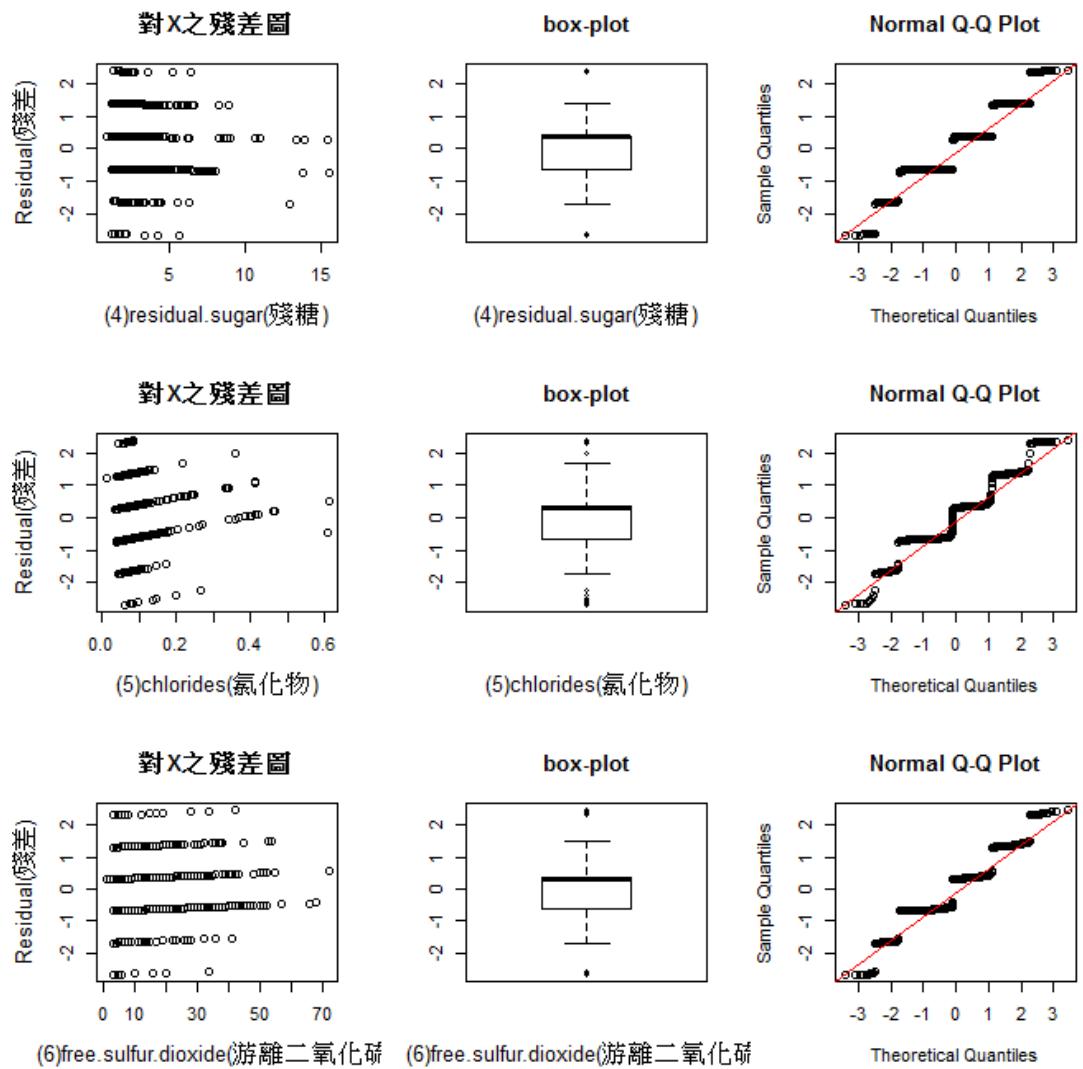
5-3 殘差對 X 的散佈圖，以及殘差的常態分配圖(boxplot & Q-Q plot)

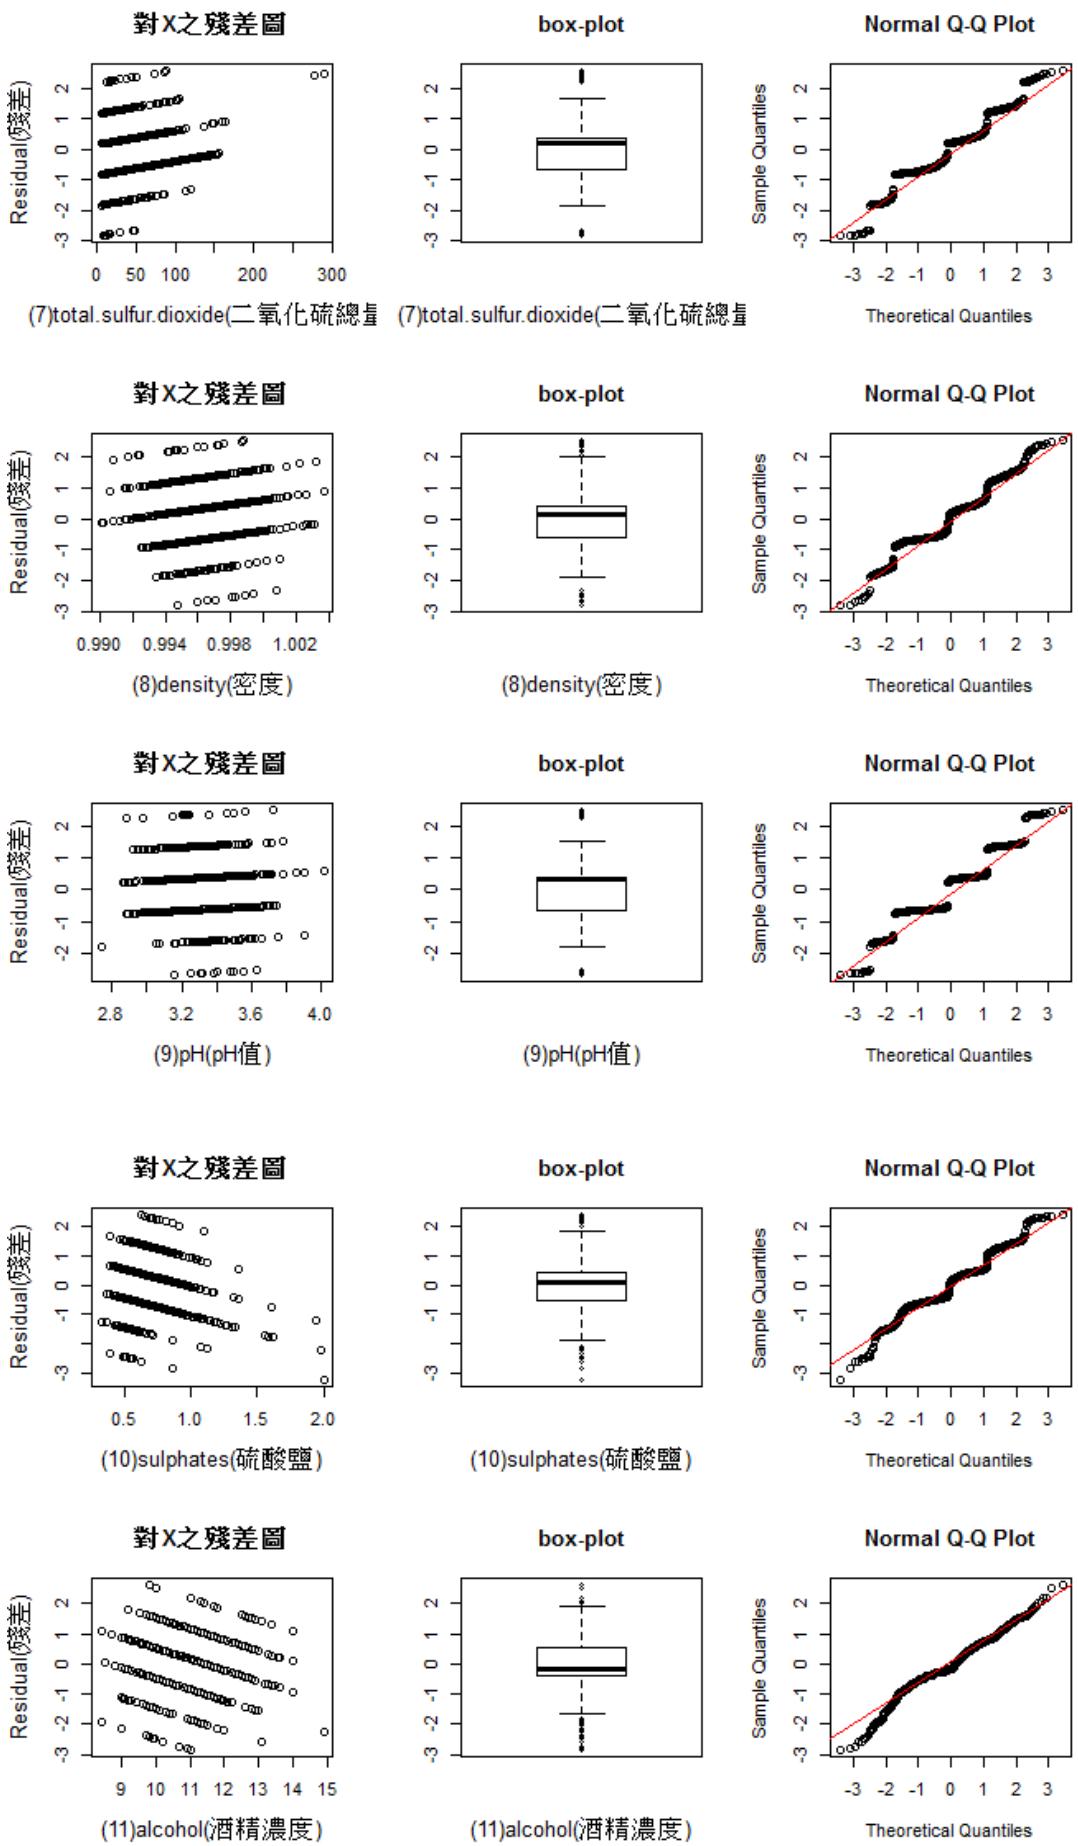
【R code】

```
# 【5-3.殘差分析】----
choice.X <- c(1:11)
# choice.X <- c(2,10,11)    #可以只選擇某些解釋變數
mod <- character()
cnt <- 0
for (i in choice.X) {
  if (cnt%%3==0) {
    dev.new()
    par(mfrow=c(3,3))
  }
  cnt <- cnt + 1
  f <- formula(paste0("quality~",names(red.wine)[i]))
  lm.model <- lm(f, data=red.wine)
  plot(red.wine[,i],resid(lm.model),cex.lab=1.2,
    xlab=paste0("(",i,")",X[i]),ylab="Residual(殘差)",
    main="對 X 之殘差圖")
  boxplot(resid(lm.model),cex.lab=1.2, outline=TRUE,
    main="box-plot", xlab=paste0("(",i,")",X[i]))
  qqnorm(resid(lm.model))
  qqline(resid(lm.model),col="red")
}
par(mfrow=c(1,1))
```

【執行結果】







5-4 Brown-Forsythe 與 Breusch-Pagan 檢定

【R code】

```
# 【5-4-1.針對 residual 進行 Brown-Forsythe Test】 ----  
install.packages("lawstat",repos = "http://cran.csie.ntu.edu.tw/")  
library(lawstat)  
# Brown-Forsythe Test 是採用 location="median"  
# Levene Test 是採用 location="mean"  
choice.X <- c(1:11)  
# choice.X <- c(2,10,11) #可以只選擇某些解釋變數  
result <- data.frame()  
p.value <- numeric(0)  
for (i in choice.X) {  
    f <- formula(paste0("quality~",names(red.wine)[i]))  
    lm.model <- lm(f, data=red.wine)  
    bf <- levene.test(resid(lm.model), red.wine[,i], location="median",  
    correction.method="zero.correction")  
    p.value = c(p.value,bf$p.value)  
}  
result <- data.frame(X.variable=X,bf.p.value=p.value);  
result[order(result$bf.p.value),]  
  
# 【5-4-2.針對 residual 進行 Breusch-Pagan Test】 ----  
install.packages("lmtest",repos = "http://cran.csie.ntu.edu.tw/")  
library(lmtest)  
choice.X <- c(1:11)  
# choice.X <- c(2,10,11) #可以只選擇某些解釋變數  
p.value <- numeric(0)  
for (i in choice.X) {  
    f <- formula(paste0("quality~",names(red.wine)[i]))  
    lm.model <- lm(f, data=red.wine)  
    bp <- bptest(lm.model)  
    p.value = c(p.value,bp$p.value)  
}  
result <- cbind(result,bp.p.value=p.value);  
result[order(result$bp.p.value),c(1,3)]  
  
# 【4-2.挑選 Brown-Forsythe Test 與 Breusch-Pagan Test 皆顯著】  
result[result$bf.p.value < 0.05 & result$bp.p.value < 0.05 ,]
```

【執行結果】

X.variable	bf.p.value
------------	------------

11	alcohol(酒精濃度)	1.251119e-08
10	sulphates(硫酸鹽)	3.045298e-02
7	total.sulfur.dioxide(二氧化硫總量)	8.915088e-02
3	citric.acid(檸檬酸)	1.703422e-01
2	volatile.acidity(揮發性酸)	3.402836e-01
5	chlorides(氯化物)	3.938061e-01
9	pH(pH 值)	5.882744e-01
4	residual.sugar(殘糖)	7.624561e-01
6	free.sulfur.dioxide(游離二氧化硫)	8.659762e-01
1	fixed.acidity(固定的酸度)	9.742309e-01
8	density(密度)	9.973763e-01

	X.variable	bp.p.value
10	sulphates(硫酸鹽)	7.927499e-19
11	alcohol(酒精濃度)	6.454021e-08
7	total.sulfur.dioxide(二氧化硫總量)	2.515996e-06
6	free.sulfur.dioxide(游離二氧化硫)	2.628626e-04
3	citric.acid(檸檬酸)	9.713534e-03
4	residual.sugar(殘糖)	9.049318e-02
5	chlorides(氯化物)	1.400066e-01
8	density(密度)	1.558287e-01
2	volatile.acidity(揮發性酸)	3.436290e-01
1	fixed.acidity(固定的酸度)	3.526455e-01
9	pH(pH 值)	6.342166e-01

BF & BP 共同顯著項目

	X.variable	bf.p.value	bp.p.value
10	sulphates(硫酸鹽)	3.045298e-02	7.927499e-19
11	alcohol(酒精濃度)	1.251119e-08	6.454021e-08

表 5-1 : Brown-Forsythe Test 與 Breusch-Pagan Test 的結果比較

序號	X.variable	bf.p.value	bp.p.value
1	fixed.acidity(固定的酸度)	9.742309e-01	3.526455e-01
2	volatile.acidity(揮發性酸)	3.402836e-01	3.436290e-01
3	citric.acid(檸檬酸)	1.703422e-01	9.713534e-03*
4	residual.sugar(殘糖)	7.624561e-01	9.049318e-02
5	chlorides(氯化物)	3.938061e-01	1.400066e-01
6	free.sulfur.dioxide(游離二氧化硫)	8.659762e-01	2.628626e-04*
7	total.sulfur.dioxide(二氧化硫總量)	8.915088e-02	2.515996e-06*
8	density(密度)	9.973763e-01	1.558287e-01

9	pH(pH 值)	5.882744e-01	6.342166e-01
10	sulphates(硫酸鹽)	3.045298e-02*	7.927499e-19*
11	alcohol(酒精濃度)	1.251119e-08*	6.454021e-08*

【說明】

以上針對 11 個解釋變數進行 Brown-Forsythe 檢定，只有(10) sulphates(硫酸鹽) 和(11)alcohol(酒精濃度)兩個變數顯著，也就代表其殘差的變異數不是常數，其他變數的殘差變異數都是常數。至於 Breusch-Pagan 檢定，結果(3)citric.acid(檸檬酸)、(6)free.sulfur.dioxide(游離二氧化硫)、(7)total.sulfur.dioxide(二氧化硫總量)、(10)sulphates(硫酸鹽)以及(11)alcohol(酒精濃度)顯著，代表這幾個變數的誤差項不是常數變異數。兩個檢定皆顯著的只有(10) sulphates(硫酸鹽) 和(11)alcohol(酒精濃度)兩個變數。

5-5 配適不佳的 F 檢定(F Test for Lack of Fit)

本資料集符合在一個或多個 X 水準下重複多個觀測值的情況下，所以以下使用『F Test for Lack of Fit』來進行 11 個解釋變數的配適檢定。

【R code】

```
# 【5-5.Proc reg (Lack of Fit) 看配適的迴歸線】----
choice.X <- c(1:11)
# choice.X <- c(2,10,11)    #可以只選擇某些解釋變數
p.value <- numeric(0)
for (i in choice.X) {
  f <- formula(paste0("quality~",names(red.wine)[i]))
  lm.model <- lm(f, data=red.wine)
  SSE <- anova(lm.model)[2,2]
  SSE.df <- anova(lm.model)[2,1]
  #以下區分不同的 X 水準
  lm.model <- lm(red.wine$quality~factor(red.wine[,i]))
  SSPE <- anova(lm.model)[2,2]
  SSPE.df <- anova(lm.model)[2,1]
  SSLF <- SSE - SSPE
  SSLF.df <- SSE.df-SSPE.df
  F.stat <- (SSLF/SSLF.df)/(SSPE/SSPE.df)
  p.val <- 1.0 - pf(F.stat, (SSE.df-SSPE.df), SSPE.df)
  p.value = c(p.value,p.val)
}
result <- data.frame(X 變數=X,p.val=p.value)
result[order(result$p.val),]
```

【執行結果】

	X 變數	p.val
1	fixed.acidity(固定的酸度)	1.838951e-05

```

2      volatile.acidity(揮發性酸) 2.445089e-03
3              citric.acid(檸檬酸) 8.846394e-09
4              residual.sugar(殘糖) 1.056613e-07
5              chlorides(氯化物) 3.024990e-05
6 free.sulfur.dioxide(游離二氧化硫) 6.806567e-01
7 total.sulfur.dioxide(二氧化硫總量) 2.380280e-02
8                  density(密度) 2.865407e-07
9                  pH(pH 值) 4.710541e-03
10 sulphates(硫酸鹽) 0.000000e+00
11 alcohol(酒精濃度) 1.330848e-04

```

【說明】

依據以上配適不佳之 F 檢定結果，除了『**free.sulfur.dioxide(游離二氧化硫)**』不顯著以外，其他 X 變數全都顯著。也就是說，在 11 個解釋變數中，只有『**(6)free.sulfur.dioxide(游離二氧化硫)**』的迴歸函數是線性函數，其他皆不是。

5-6 解釋變數 X 的轉換

由於本資料集的分佈較為特殊，所以以下同時採用三種模式來進行 11 個 X 變的轉換，再透過轉換後的 Q-Q plot 來進行觀測。

【R code】

```

# 【5-6.資料轉換 X】----
choice.X <- c(1:11)
# choice.X <- c(2,10,11)    #可以只選擇某些解釋變數
mod <- character()
cnt <- 0
for (i in choice.X) {
  if (cnt%%3==0) {
    dev.new()
    par(mfrow=c(3,4))
  }
  cnt <- cnt + 1
  f <- formula(paste0("quality~",names(red.wine)[i]))
  lm.model <- lm(f, data=red.wine)
  qqnorm(resid(lm.model),col="red",cex.lab=1.1,ylab="殘差",
         main="轉換前 Q-Q plot",
         sub=paste0("(",i,")",names(red.wine)[i]))
  qqline(resid(lm.model))

  x.new <- log10(ifelse(red.wine[,i]==0,1,red.wine[,i]))
  lm.model <- lm(red.wine$quality~x.new)
  qqnorm(resid(lm.model),col="orange",cex.lab=1.1,ylab="殘差",
         main="轉換後 Q-Q plot",
         sub=paste0("(log10)",names(red.wine)[i]))
```

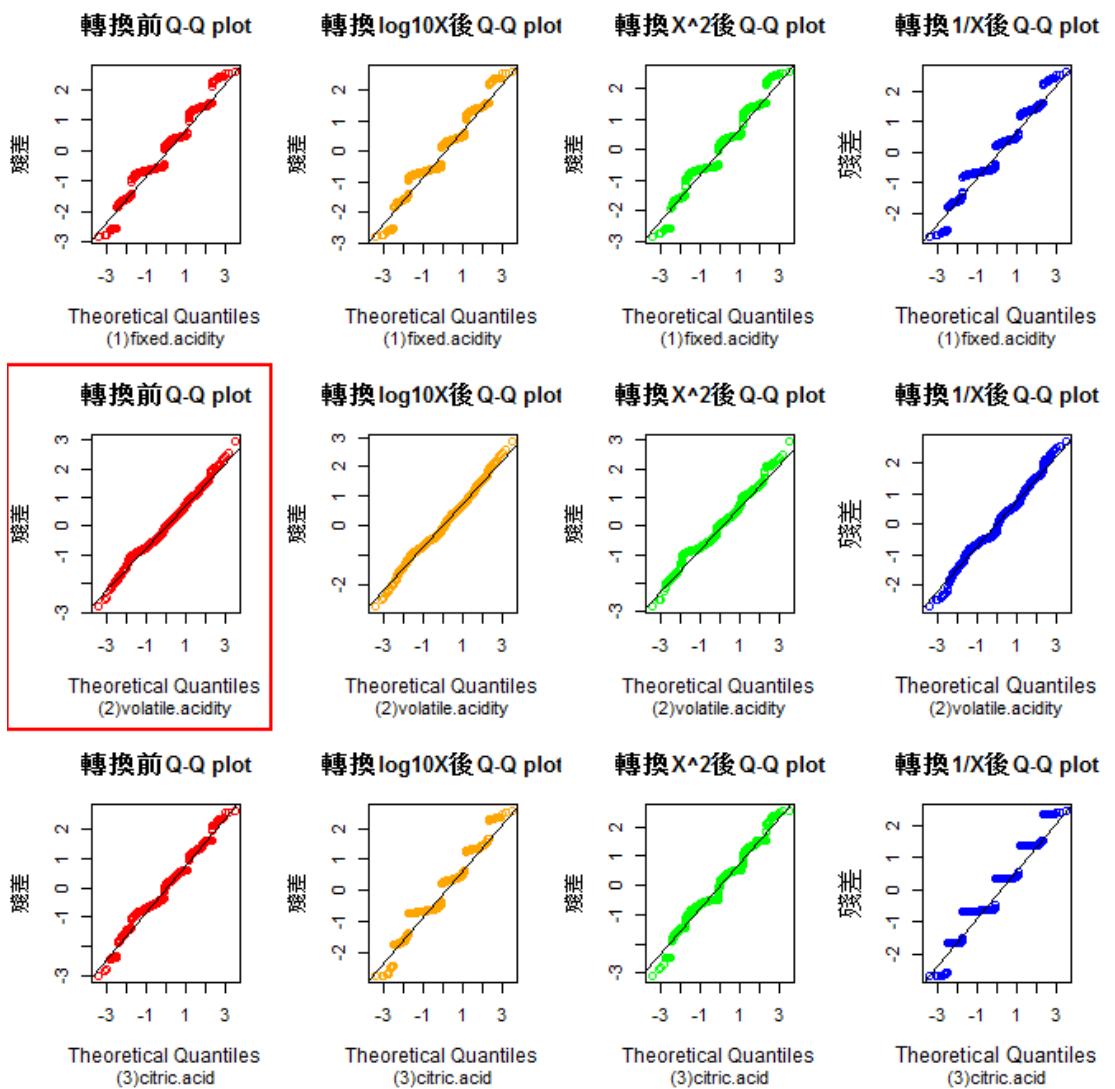
```
main="轉換 log10X 後 Q-Q plot",
sub=paste0("(",i,")",names(red.wine)[i]))
qqline(resid(lm.model))

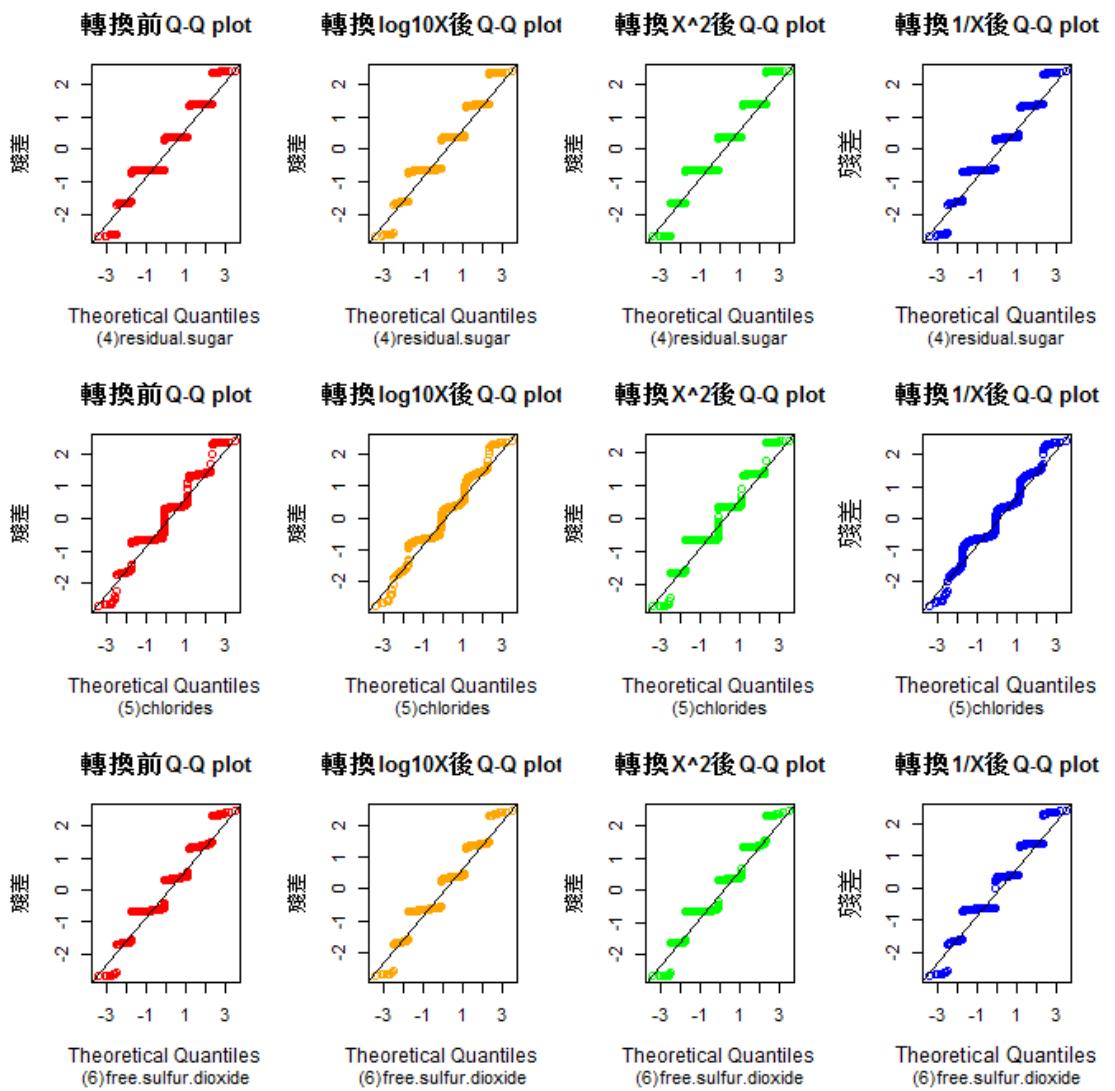
x.new <- (red.wine[,i])^2
lm.model <- lm(red.wine$quality~x.new)
qqnorm(resid(lm.model),col="green",cex.lab=1.1,ylab="殘差",
       main="轉換 X 平方後 Q-Q plot",
       sub=paste0("(",i,")",names(red.wine)[i]))
qqline(resid(lm.model))

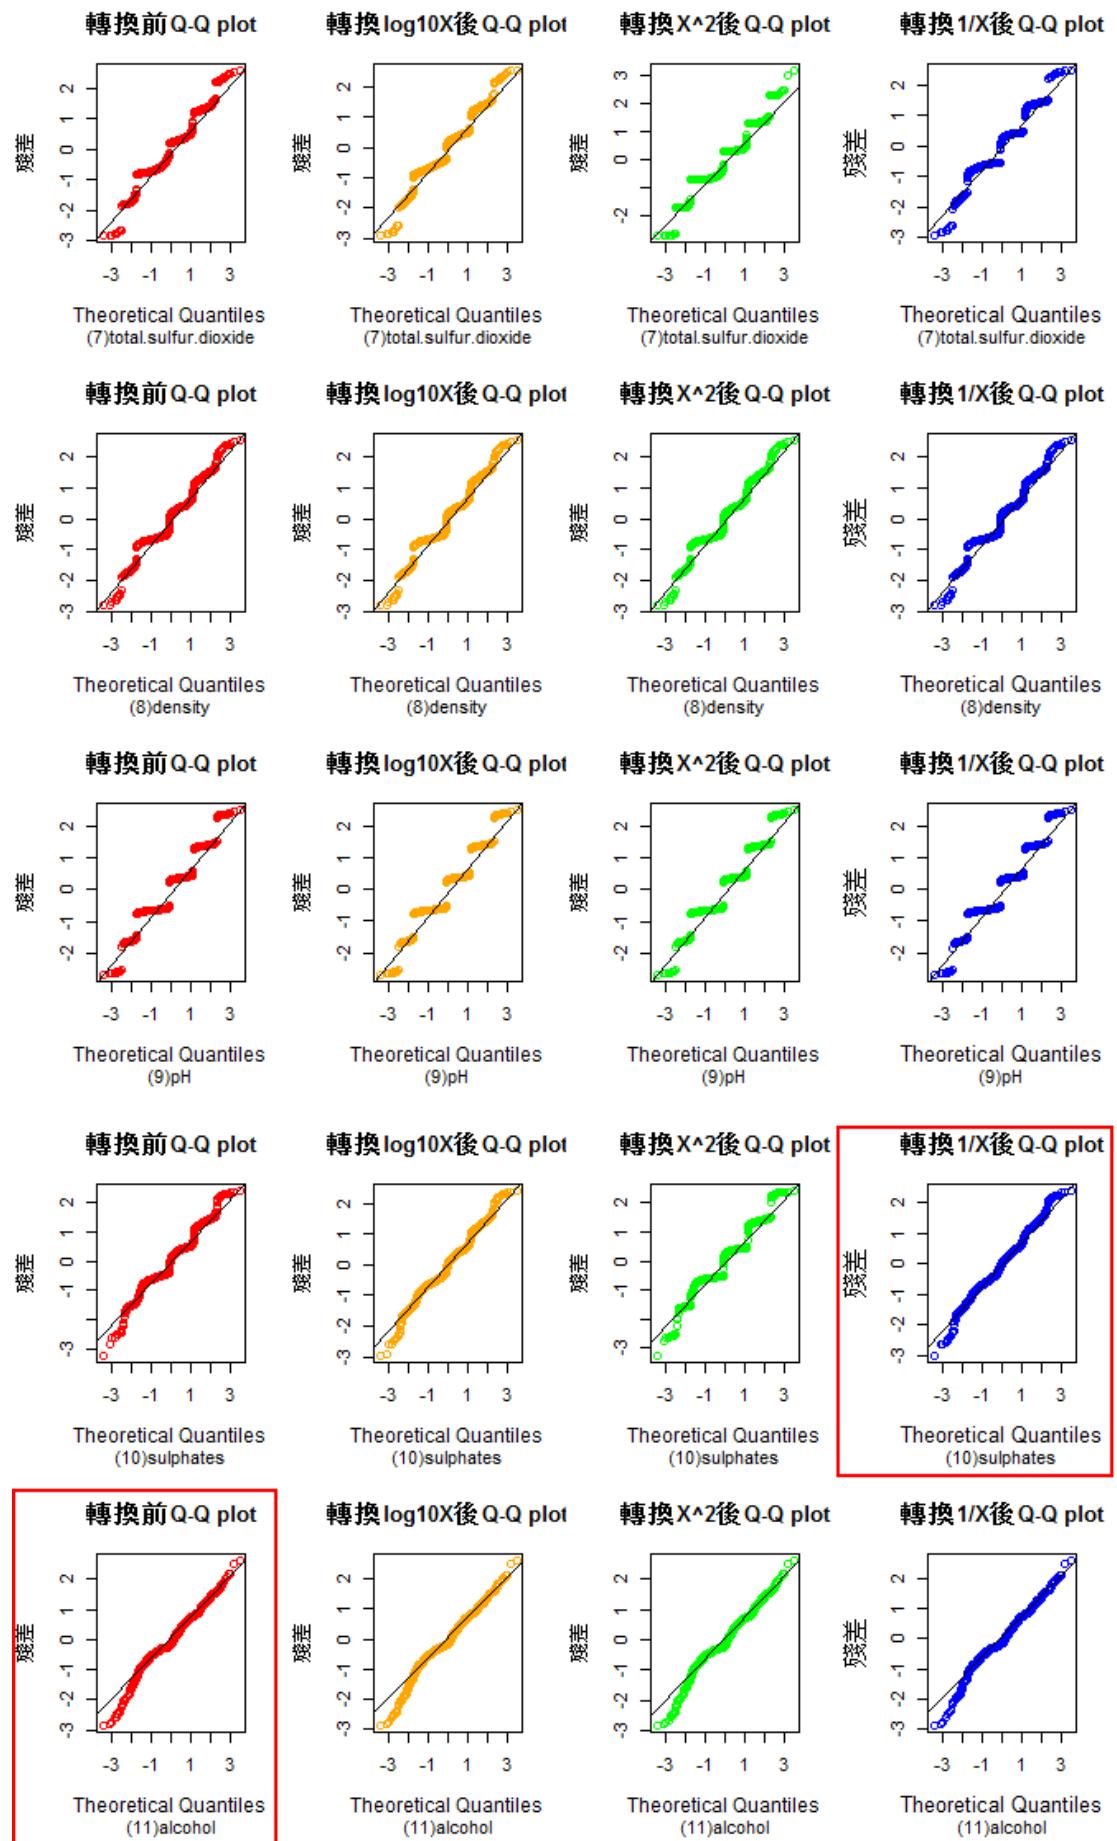
x.new <- ifelse(red.wine[,i]==0,0,1/red.wine[,i])
lm.model <- lm(red.wine$quality~x.new)
qqnorm(resid(lm.model),col="blue",cex.lab=1.2,ylab="殘差",
       main="轉換 1/X 後 Q-Q plot",
       sub=paste0("(",i,")",names(red.wine)[i]))
qqline(resid(lm.model))
}

par(mfrow=c(1,1))
```

【執行結果】







【說明】

從以上 11 個解釋變數，利用三種轉換方式(Log10、X2 以及 1/X)所得結果，可以得到較好的結果，僅有(10)sulphates(硫酸鹽)透過 1/x 的轉換是最好的一個。而(2)volatile acidity(揮發性酸)原本就已經很符合常態，(11)alcohol(酒精)也還可以。

5-7 殘差的常態分配檢定(Shapiro-Wilk)

【R code】

```
# 【5-7 殘差的常態分配檢定(Shapiro-Wilk)】  
choice.X <- c(1:11)  
# choice.X <- c(2,10,11)    #可以只選擇某些解釋變數  
p.value <- numeric(0)  
for (i in choice.X) {  
  f <- formula(paste0("quality~",names(red.wine)[i]))  
  lm.model <- lm(f, data=red.wine)  
  s <- shapiro.test(resid(lm.model))  
  p.value = c(p.value,s$p.value)  
}  
result <- cbind(X[1:11],p.value);result
```

【執行結果】

	p.value
[1,] "fixed.acidity(固定的酸度)"	"1.32503571687972e-27"
[2,] "volatile.acidity(揮發性酸)"	"8.68866795703351e-10"
[3,] "citric.acid(檸檬酸)"	"3.02180649952336e-18"
[4,] "residual.sugar(殘糖)"	"3.9217831204756e-35"
[5,] "chlorides(氯化物)"	"1.24763891653593e-31"
[6,] "free.sulfur.dioxide(游離二氧化硫)"	"1.41771759914014e-32"
[7,] "total.sulfur.dioxide(二氧化硫總量)"	"4.43113672448884e-24"
[8,] "density(密度)"	"4.55664047578531e-24"
[9,] "pH(pH 值)"	"5.66241131707243e-32"
[10,] "sulphates(硫酸鹽)"	"3.31594008875393e-21"
[11,] "alcohol(酒精濃度)"	"8.86454266844593e-16"

【說明】

通常使用 Shapiro-Wilk 來做常態分配檢定，根據官方資料顯示(參考如下)，通常 alpha 會定為 0.1，也就是 p.value < 0.1 才算是顯著。從以上的檢定結果，全數顯著，也代表全部的殘差都不是常態分配。

(<http://stat.ethz.ch/R-manual/R-devel/library/stats/html/shapiro.test.html>)

5-8 試著利用混合模式進行解釋變數 X 的轉變，配合反應變數 Y 的 Box-Cox 轉換

【R code】

```
install.packages("DescTools")
```

```

library(DescTools)
m <- matrix(0,nrow=11,ncol=4)
Y.new <- BoxCox(red.wine$quality, lambda = BoxCoxLambda(red.wine$quality))
for (c in 1:4) {
  for (r in 1:11) {
    if (c==1) X.new <- red.wine[,r]
    else if (c==2) X.new <- log10(ifelse(red.wine[,r]==0,1,red.wine[,r]))
    else if (c==3) X.new <- (red.wine[,r])^2
    else X.new <- ifelse(red.wine[,r]==0,0,1/red.wine[,r])
    lm.model <- lm(Y.new ~ X.new)
    s <- shapiro.test(resid(lm.model))
    m[r,c]=s$p.value
  }
}
rownames(m)<-names(red.wine)[1:11]
colnames(m)<-c("X","log10X","X^2","1/X")
m

```

【執行結果】

	X	log10X	X^2	1/X
fixed.acidity	1.188601e-27	4.723230e-28	5.271179e-28	3.788489e-29
volatile.acidity	2.995254e-10	2.584447e-10	2.285190e-16	3.008798e-16
citric.acid	2.628627e-18	8.365066e-29	1.751684e-22	2.285618e-34
residual.sugar	3.686254e-35	2.140458e-34	1.084084e-35	6.162761e-34
chlorides	1.116165e-31	1.040096e-26	2.957112e-34	2.273959e-26
free.sulfur.dioxide	1.458037e-32	2.366421e-32	1.251387e-33	1.875937e-33
total.sulfur.dioxide	4.837623e-24	4.434966e-23	8.203097e-30	1.839133e-28
density	4.560237e-24	4.748431e-24	4.378203e-24	4.942915e-24
pH	4.743017e-32	4.789191e-32	4.454705e-32	4.589167e-32
sulphates	3.191898e-21	2.893229e-14	2.706116e-28	1.768080e-10
alcohol	2.192373e-15	1.147749e-14	2.698173e-16	4.257392e-14

【說明】

經過以上同時對不同的 X 以及 Y 變數的不同轉換，以及利用 Shapiro-Wilk 對轉換後的殘差進行常態檢定方式，很不幸地，全數都顯著，也就是經過轉換後，殘差仍然無法呈現常態分配。

參考資料

<http://archive.ics.uci.edu/ml/datasets/Wine+Quality>